

面向 MS/MS 分子检索的非生成式学习排序方法

匿名作者

摘要

从串联质谱中检索分子结构具有较大挑战，因为大量候选分子可能具有相同或相近的质量、分子式和子结构。联合嵌入方法按谱图-分子相似度排序，生成式检索则可能引入自回归分子解码器。本文研究另一种技术路线：直接对已检索分子列表进行非生成式学习排序。我们构建 SpecEmbedding-Rerank：第一阶段对齐峰序列谱图编码器和分子图编码器；第二阶段在 listwise 监督下，综合谱图与候选嵌入、显式交互特征、基础分数和原始排名进行残差重排序。我们在 canonical 第一阶段 checkpoint 和 cache 上，使用三个 reranker 随机种子比较不含学习式跨候选交互的 pointwise 打分器与候选集合 Transformer，并对 alignment seeds 42-44 另行完成分层分析。在包含 17,556 条测试查询的 MassSpecGym 上，canonical 结果中两者的 Recall@1 (三种子均值 $\pm$ 样本标准差) 在质量约束场景分别为 67.44 ± 0.74 和 68.58 ± 0.20 ，在分子式约束场景分别为 73.97 ± 0.59 和 74.57 ± 0.28 ，而固定基础检索器分别为 47.46 和 63.10。Recall 和 MRR 使用所提供候选文件上的本地 exact-target-SMILES 单正例规则；该规则与参考二维 InChIKey/可能多正例规则的影响差异尚未量化，因此这些结果不等价于官方 evaluator。三个 alignment seeds 中，两种学习式排序器在 Recall@1 和 MRR 的 12 个 alignment-候选-学习模型聚合单元均优于对应 base，但 Transformer-pointwise 的方向随 alignment 改变。固定 alignment 的五项移除设置审计中，没有任何设置使完整模型在两类候选协议的每个按 reranker seed 配对的比较中均获得更高 MRR；去除排名嵌入反而在全部六个候选协议与种子的配对中同时提高 Recall@1 和 MRR。因此，当前证据支持监督、非生成式第二阶段重排序框架，但尚不能确认候选间自注意力或任一受审计组件具有稳健的独立收益。两种变体都不需要自回归分子生成，测试时也不把真实目标强制放入截断后的 top-40 列表。

关键词：生物信息学数据挖掘；串联质谱；分子检索；学习排序；多模态表示学习

1 引言

串联质谱 (MS/MS) 被广泛用于代谢组学、天然产物发现和相关生物医学任务中的小分子鉴定。实验谱图只是分子结构在特定实验条件下的部分观测：不同分子可能产生相似碎片，同一分子也可能因仪器、加合物和碰撞能量不同而产生差异明显的谱图。因此，结构注释天然属于一个大规模数据挖掘问题，即根据查询谱图，从受化学条件约束的候选池中检索并排序正确分子。

MassSpecGym 提供了结构不重叠的数据划分，以及标准化的质量约束和分子式约束检索候选池 [3]。现有方法主要尝试缩小谱图和分子之间的模态差距。JESTR 使用 contrastive multiview coding 学习谱图-分子联合空间，并直接按余弦相似度排序候选 [13, 21]。GLMR 则先检索上下文候选，再利用条件语言模型生成 refined molecule，最后根据分子-分子相似度重排候选 [25]。

这两类方法仍留下一个重要的数据挖掘问题。固定的 pairwise 余弦分数并不直接优化最终候选顺序；生成式检索则引入自回归解码器，最终排序依赖生成结构的质量和有效性。本文研究能否用监督的第二阶段排序器直接区分 hard candidates，以及候选间显式交互是否比 pointwise 残差打分提供额外收益。

本文基于 SpecEmbedding 提出的峰序列谱图架构 [23] 构建 SpecEmbedding-Rerank 两阶段框架。第一阶段从零训练该谱图塔，并将其与 GINE 分子图编码器对齐；第二阶段只处理基础检索的 top- K 列表，显式构造谱图-候选交互特征，将基础分数和排名作为检索先验，并预测对基础分数的残差修正。本文比较 pointwise 与候选集合 Transformer 两种实现。

本文贡献如下：

- 将面向 MS/MS 分子检索的直接、非生成式第二阶段 learning-to-rank 构建为可评估方案，同时避免固定余弦打分和自回归分子解码。
- 在相同输入特征、score head、损失和优化协议下比较 pointwise 与 self-attentive 两种实现，并保持第一阶段嵌入可缓存；在相同固定 cache 上进一步审计残差 shortcut、联合基础分数路径、排名嵌入、乘积/绝对差特征和 pairwise loss 五项设计选择。
- 在 MassSpecGym 划分和候选文件上，并按本地 exact-SMILES 单正例规则评价，两种实现均在 alignment seeds 42–44 上优于各自固定的基础检索器；候选集合 Transformer 相对 pointwise 的方向在三个 checkpoint 间并不一致，因此未能建立稳健的自注意力收益；在 canonical 固定 alignment 的组件审计中，五项移除设置也均未使完整模型在两类候选协议下取得一致的成对 MRR 优势。

AI 使用披露。 OpenAI Codex 在本稿所有章节中辅助文字起草和语言修改，并在项目过程中辅助代码编辑、实验编排和结果一致性审计。文中实验观测和数值来自所述软件流水线，而非 AI 模型生成。作者已审阅全部 AI 辅助文字与代码，核验技术论述、引用、保存的实验工件和报告结果，并对稿件的准确性、完整性和原创性承担全部责任。

2 相关工作

2.1 结构注释范式

计算式 MS/MS 注释方法在检索对象和排序证据上均有差异，候选分数修正和二阶段重排也并非本文首次提出。MetFusion 融合 MetFrag 的 in-silico fragmentation 结果与 MassBank 谱图库证据，以改善候选化合物排序 [9]。MS2Query 先用 MS2DeepScore 选取 top-2000 谱图库匹配，再用包含五个特征的随机森林重排，并允许按分数阈值过滤低可信匹配 [7]。LC-MS2Struct 则将已有 MS/MS scorer 与同一液相色谱实验中的观测保留顺序结合，联合排序多个待注释物的结构候选 [1]。这些谱图库邻居或保留时间证据与 MassSpecGym 的查询特定结构候选排序互补 [3]。

表 1: 本文方法与最接近 MassSpecGym 方法的机制对比。

方法	最终排序信号	候选间交互	生成分子	优化阶段
JESTR	谱图-候选余弦相似度	推理时无	否	InfoNCE 加分子式候选正则
GLMR	生成分子-候选余弦相似度	生成器内部 cross-attention	是	dual-path InfoNCE 加自回归生成
本文	pair 特征和检索先验预测的残差分数	set-aware 变体可选 self-attention	否	跨模态 InfoNCE 加 listwise/pairwise 重排序

在结构数据库检索中, CSI:FingerID 和 MIST 从谱图预测分子指纹 [8, 10]。CMSSP、JESTR 和 MVP 则通过对比学习建立谱图-分子联合空间 [5, 13, 6]; 其中 MVP 同时对齐分子图、指纹、单条谱图和 consensus spectra。这些方法最终使用预测指纹分数或跨模态相似度排序候选。SpecEmbedding 研究谱图-谱图表示学习 [23]。本文只复用其峰序列架构, 并从零开始将其与分子图对齐, 研究互补的第二阶段问题: 如何学习已有 hard-candidate 列表内部的顺序。

谱图模拟与结构生成使用不同的中间表示。MassFormer 根据分子图预测串联质谱 [24]; MSNovelist 根据 MS/MS 推导的指纹生成结构 [20]。GLMR 对齐谱图和分子表示, 以预检索候选为条件生成分子, 再按生成分子与候选的相似度排序 [25]。本文不解码结构, 而是闭集候选重排序器: 它不能返回第一阶段列表之外的分子, 但直接优化已有候选的分数。

2.2 学习排序与候选集合建模

learning-to-rank 使用候选偏好或完整列表定义监督, 而不是把相似度排序作为固定后处理。RankNet 学习 pairwise 偏好, ListNet 则对完整排序列表建立概率模型 [2, 4]。排序函数还可利用竞争候选之间的关系。Set Transformer 为集合输入提供基于注意力的模块 [15]; SetRank 在保持置换等变性的同时联合建模文档间交互 [17]。本文将这些原则迁移到谱图-分子检索, 结合缓存的跨模态嵌入、显式 pair interactions 以及第一阶段分数和排名先验。本文的贡献并非 reranking、self-attention 或 listwise 学习本身, 而是在冻结的跨模态表示上进行查询特定、非生成式第二阶段排序, 并在相同固定候选列表上受控比较 pointwise 打分器、候选集合模型及五项组件移除; pointwise 与候选集合架构比较使用匹配的特征和目标。本方法不依赖谱图库邻居或保留时间。

2.3 本文方法的定位

表 1 对比最接近的 MassSpecGym 方法的排序机制。结合上述先例, 本文贡献并非重排序本身, 而是冻结跨模态表示上的查询特定、非生成式第二阶段排序; 残差打分和候选间自注意力均是被受控评估的设计选项, 而不是预先假定的增益来源。

3 问题定义

记 s 为一条 MS/MS 谱图, m^+ 为真实分子, $\mathcal{D}_s$ 为查询对应的质量约束或分子式约束的所提供候选池。基础检索器为每个 $m \in \mathcal{D}_s$ 计算

$$b(s, m) = \text{sim}(f_s(s), f_m(m)), \quad (1)$$

并返回 top- K 列表 $\mathcal{C}_s = (m_1, \dots, m_K)$ 。重排序器学习 $g(s, m_i, \mathcal{C}_s)$, 使 m^+ 的排名尽可能靠前。由于重排序器无法返回 $\mathcal{C}_s$ 之外的分子, 端到端 Recall@ k 的上界为

$$U_K = \frac{1}{N} \sum_{n=1}^N \mathbb{I}[m_n^+ \in \mathcal{C}_{s_n}]. \quad (2)$$

对已进入 top- K 的正例, 定义条件排序成功率

$$A_{k|K} = \frac{\sum_{n=1}^N \mathbb{I}[m_n^+ \in \mathcal{C}_{s_n}, \text{rank}_g(m_n^+) \leq k]}{\sum_{n=1}^N \mathbb{I}[m_n^+ \in \mathcal{C}_{s_n}]}, \quad \text{Recall@}k = U_K A_{k|K} \leq U_K. \quad (3)$$

这是指标定义的恒等分解。在固定 top- K cache 时, reranker 只能改变列表内的 $A_{k|K}$, 不能改变第一阶段覆盖率 U_K 。因此, 我们同时报告 U_K 和面向全部查询的排序指标; 如果正例不在 top- K 中, 该查询记为零, 而不是只在成功召回的子集上报告条件准确率。

4 方法

4.1 总体框架

框架包含跨模态对齐、top- K 检索和监督残差重排序三个步骤。训练 reranker 时冻结谱图和分子编码器, 因此两个模态的嵌入可以离线计算并重复使用。

4.2 跨模态基础检索器

谱图编码器沿用 SpecEmbedding 的峰序列架构 [23]: 结合正弦 m/z 特征和 Transformer, 处理峰的 m/z 与强度序列。每条谱图最多表示为 100 个 token: 第一个 token 是强度设为 2 的前体 m/z , 其后为按强度选出的至多 99 个碎片峰。被选碎片恢复其在源数组中的顺序, 强度除以所选碎片的最大强度。谱图编码器只接收这些 m/z -强度 token; 加合物、仪器和碰撞能量元数据均不是显式输入。本文从零初始化该谱图塔, 并将它用于谱图-分子而非谱图-谱图对齐。分子编码器是基于原子和化学键特征的 GINE [12], 并将 mean-pooled 图特征与显式图规模特征拼接。两个投影头将编码结果映射到统一的 d 维空间:

$$\mathbf{z}_s = \frac{p_s(f_s(s))}{\|p_s(f_s(s))\|_2}, \quad \mathbf{z}_m = \frac{p_m(f_m(m))}{\|p_m(f_m(m))\|_2}. \quad (4)$$




图 1: SpecEmbedding-Rerank 总体流程。面板 1 对齐谱图 Transformer 和分子 GINE；面板 2 使用冻结、缓存的嵌入构造 top-40 列表；面板 3 在共享候选特征上采用 pointwise 打分或候选集合自注意力，并向基础分数加入残差。虚线表示仅训练时使用的操作；验证和测试均不执行强制 top-40 目标替换，整个流程不生成分子。

基础模型使用双向跨模态多正例对比损失。具有相同分子标签的谱图和分子均作为正例，从而避免把同一分子的重复谱图误当成负例。对大小为 B 的 minibatch，记 $P(i)$ 为与样本 i 具有相同标签的索引集合。使用可学习逆温度尺度 a ，基础 logits 为

$$\ell_{ij} = a \mathbf{z}_{s_i}^\top \mathbf{z}_{m_j}. \quad (5)$$

spectrum-to-molecule 项为

$$\mathcal{L}_{s \rightarrow m} = -\frac{1}{B} \sum_{i=1}^B \frac{1}{|P(i)|} \sum_{j \in P(i)} \log \frac{\exp(\ell_{ij})}{\sum_{k=1}^B \exp(\ell_{ik})}. \quad (6)$$

molecule-to-spectrum 项对 $\ell^\top$ 使用同一表达式，两项取均值得到 alignment loss。实现令 $a = \exp(u)$ 并将其上限截为 100。推理时，归一化点积 $b_i = \mathbf{z}_s^\top \mathbf{z}_{m_i}$ 作为基础分数。

4.3 候选构造与训练协议

基础检索器对每条查询对应的 MassSpecGym 所提供候选池打分，并保留 top- K ，当前实验取 $K = 40$ 。监督训练要求候选列表中存在正例。如果真实训练分子未进入基础 top-40，则用它替换最后一个候选，同时在 cache 中保留其在所提供完整候选池中的基础排名；该目标排名等于基础分数严格高于它的候选数加一，与目标同分的候选不计为排名更高。排名嵌入接收 $\bar{r}_i = \min\{\max(r_i, 0), 512\}$ ，其中索引 0 专用于 padding。训练 reranker 时随机打乱候选顺序，但每个候选的嵌入、基础分数和排名始终同步移动；这是防止 cache 顺序伪特征的额外保护。

待打分候选池是标签目标与文件候选按 exact SMILES 去重后的并集。静态审计显示，目标已经存在于全部 32,010 个冻结候选池中，因此该并集没有扩大候选池。与此不同，仅训练集执行检

索后的强制替换：它将未进入基础 top-40 的 exact target 放入截断列表。验证和测试不执行该替换。未进入基础 top-40 的真实目标因此保持缺失，并降低召回上界和全部端到端指标。任何被分配到测试划分的记录、测试目标或标签都不用于任一阶段的参数优化或 checkpoint 选择。

4.4 残差重排序器变体

对基础排名为 r_i 的候选 m_i ，构造

$$\mathbf{x}_i = [\mathbf{z}_s, \mathbf{z}_{m_i}, \mathbf{z}_s \odot \mathbf{z}_{m_i}, |\mathbf{z}_s - \mathbf{z}_{m_i}|, b_i, \mathbf{e}(\bar{r}_i)], \quad (7)$$

其中 $\mathbf{e}(\bar{r}_i)$ 是可学习排名嵌入。直接嵌入保留模态信息，元素乘积和绝对差则显式提供对称匹配信号。MLP 将特征投影为

$$\mathbf{h}_i = \text{MLP}(\mathbf{x}_i). \quad (8)$$

两种变体的实际输入仅包括冻结的谱图嵌入、冻结的候选分子嵌入、余弦基础分数、截断后的基础排名嵌入和候选 padding mask。原始谱峰、SMILES token、前体质量或分子式以及采集元数据均不直接输入 reranker。质量与分子式约束只影响候选池构造，模型也不接收显式的候选-候选结构相似度特征。

set-aware 变体使用不含候选位置编码的 Transformer encoder 在候选之间交换信息 [22]：

$$[\tilde{\mathbf{h}}_1, \dots, \tilde{\mathbf{h}}_K] = \text{Transformer}([\mathbf{h}_1, \dots, \mathbf{h}_K]). \quad (9)$$

padding mask 支持不同长度的候选列表。因此，在关闭 dropout 的确定性推理时，将候选及其对应的嵌入、分数和排名共同置换，输出分数也按同一方式置换；排名是随候选移动的检索先验，而不是张量槽位编码。这一设计与置换等变的集合排序表述一致 [15, 17]。pointwise 对照令 $\tilde{\mathbf{h}}_i = \mathbf{h}_i$ ，保留相同输入特征、pair MLP、score head、残差路径、训练损失和优化协议，仅移除构造检索先验之后的学习式候选间交互。该对照没有匹配参数量或模型容量：pointwise 与候选集合 Transformer 分别包含 1,478,690 和 7,783,458 个可训练 reranker 参数。score head 预测修正值 Δ_i ，最终采用残差分数

$$q_i = \alpha b_i + \Delta_i, \quad (10)$$

标量 α 初始化为 1.0，训练时不施加符号或取值范围约束； Δ_i 同样不受约束。因此，该 shortcut 使排序器能够直接访问基础分数，但既不约束 q_i 必须接近 b_i ，也不保证最终排序保留基础顺序。由于 b_i 还是 $\mathbf{x}_i$ 的输入，残差分支可学习额外的 score-dependent effect，因而 α 不能单独解释为“保留基础分数的比例”。

4.5 训练目标

记 $\mathcal{B}_L$ 为一个 minibatch 中具有标签的查询集合, V_n 为查询 n 的有效、非 padding 候选索引集合, $y_n \in V_n$ 为其正例索引。实现首先在所有有标签查询上平均 listwise cross-entropy:

$$\mathcal{L}_{\text{list}} = -\frac{1}{|\mathcal{B}_L|} \sum_{n \in \mathcal{B}_L} \log \frac{\exp(q_{ny_n})}{\sum_{i \in V_n} \exp(q_{ni})}. \quad (11)$$

此外, 每个正例都与同一检索列表中的其他全部有效候选进行比较。实现不是先对每个可变量列表分别平均, 而是在整个 minibatch 的所有有效正负对上统一取均值:

$$\mathcal{L}_{\text{pair}} = \frac{\sum_{n \in \mathcal{B}_L} \sum_{i \in V_n \setminus \{y_n\}} \log(1 + \exp(q_{ni} - q_{ny_n} + \gamma))}{\sum_{n \in \mathcal{B}_L} (|V_n| - 1)}. \quad (12)$$

总损失为

$$\mathcal{L} = \mathcal{L}_{\text{list}} + \lambda \mathcal{L}_{\text{pair}}. \quad (13)$$

其中 listwise 项是一正例、多候选的 top-one likelihood, 不规定负例之间的完整全序。两个损失都对同一查询内全部 q_i 加上任意相同常数保持不变。因此, 原始 q_i 是相对排序分数而非概率; 本文既未执行也未评价概率校准。

对于 L 层 Transformer 和隐藏维度 h , set-aware 变体比 pointwise 打额外引入 $O(L(Kh^2 + K^2h))$ 计算和 $O(LK^2)$ 注意力内存。两者都不需要逐 token 生成分子。本文不报告与 GLMR 的同硬件实测 latency 对比, 因此不作实际推理速度声明。

5 实验

5.1 数据集与候选池

我们使用 MassSpecGym 官方划分 [3], 包含 194,119 条训练谱图、19,429 条验证谱图和 17,556 条测试谱图, 共计 231,104 条谱图; 基准论文报告约 29,000 个唯一分子结构。其划分按结构相似性分组, 使测试分子与训练分子具有明显结构差异。

对完整谱图记录签名 (峰数组、前体 m/z 、加合物、仪器和碰撞能量) 的精确审计未发现跨划分标签分子重复, 但有 6 条验证签名和 3 条测试签名与训练签名精确匹配。这 9 个匹配对的标签分子均不相同, 且对应评价查询均标记为 `simulation_challenge=true`。本文将其报告为跨划分谱图记录重叠。下文采用的 canonical 流水线在所有依赖验证集的模型选择阶段排除这 6 条验证谱图, 使 reranker 验证查询数变为 19,423; alignment 的验证分子键数从 3,386 降至 3,384。测试阶段仍保留并评价官方全部 17,556 条查询。

实验评估 MassSpecGym 提供的两种候选设置。质量约束候选池使用前体质量和容差窗口; 分子式约束候选池假设已知分子式, 因此应解释为 formula-conditioned retrieval, 而不是完全开放的未知结构注释。冻结候选池至多包含 256 个候选。截断前, 测试查询的候选数在质量和分子式场景

下平均为 253.88 和 165.75；对应 17,556 条查询中，分别只有 1 条和 3,159 条的候选数少于 40。经过 top-40 截断后，平均候选数为 40.00 和 35.73。

本地 cache 和 evaluator 以 exact target-SMILES equality 定义唯一正例。在官方代码 commit 4f501b3 中，¹参考 loader 默认使用二维 InChIKey 等价规则，可能标出多个正例。因此，本文 Recall 和 MRR 使用所提供候选文件上的 exact-SMILES 本地协议；身份规则差异的影响尚未量化。

5.2 实现细节

对齐模型输出 512 维嵌入。谱图 Transformer 为 4 层、16 个 attention heads、宽度 512；分子 GINE 为 4 层、隐藏宽度 128、dropout 0.2。当前实验不加载已发布的 SpecEmbedding checkpoint，因此跳过原本会冻结预训练谱图塔的 alignment 阶段，并在 MassSpecGym 训练集上端到端优化两个编码塔。alignment 使用 AdamW，batch size 128，学习率 10^{-4} ，weight decay 10^{-4} ，cosine schedule，gradient-norm clipping 为 1，最多 100 个 epoch，early stopping patience 为 5。每个 epoch 对每个唯一分子标签采样 10 次，每次随机选择一条关联谱图。谱图和分子图增强分别以 0.5 概率启用：谱图增强删除归一化强度低于 0.3 的碎片峰中 20%（向下取整），并进行 $\pm 15\%$ 强度扰动；图增强执行 10% node dropout 和 10% directed edge-entry dropout。验证关闭增强，但在固定随机流下保留关联谱图的随机采样。canonical seed-42 alignment 实验应用上述验证排除，选择 epoch 16，并于 epoch 21 停止。

reranker 隐藏维度为 512，rank embedding 为 32 维，dropout 为 0.1。set-aware 变体使用两层 Transformer 和八个 attention heads，pointwise 对照移除这两层。优化器为 AdamW，学习率 10^{-4} ，batch size 16，最多训练 30 个 epoch，并根据验证集 MRR 进行 patience 为 5 的 early stopping。 $\lambda = 0.2$ ， $\gamma = 0.1$ 。canonical 受控分析固定 alignment seed 42 的 overlap-clean checkpoint 和 cache，两种变体均使用 reranker seeds 42、43 和 44 训练；相应样本标准差只衡量给定第一阶段下的 reranker 变异。独立的跨 alignment 敏感性分析对 alignment seeds 42、43 和 44 分别使用相同三个 reranker seeds，并先在每个 alignment 内聚合。因此跨 alignment 的统计单位是三个 alignment checkpoints，而不是展平后的九次运行。组件审计仍只使用 canonical alignment seed 42 的 cache 和 reranker seeds，其五项移除分别为：只关闭残差 shortcut、但仍保留基础分数作为 MLP 输入；同时关闭基础分数特征和残差路径；以零向量替代排名嵌入并保持输入宽度；去除乘积与绝对差特征但保留 self-attention；以及令 $\lambda = 0$ 、只保留 listwise 训练。所有模型均不访问测试集进行选择，并在单张 NVIDIA RTX 4090 上评估。

训练集中，执行仅训练使用的强制正例替换之前，基础 top-40 召回上界在质量和分子式场景下分别为 93.78% 和 90.42%；按前述训练协议补全后，训练列表的 labeled coverage 为 100%。测试阶段不把真实目标强制放入 top-40，对应上界分别为 83.88% 和 89.26%。

¹MassSpecGym reference loader 与 label transform，访问日期：2026-08-01。

表 2: 代表性本地 MassSpecGym 结果。Base 使用 alignment seed 42, 学习式行使用 reranker seed 42。Recall 和 MRR 以百分比报告, 采用所提供候选文件上的本地 exact-target-SMILES 单正例规则, 并不等价于官方 evaluator。MCES@1 为本地经过阈值处理的 myopic-MCES 输出, 越低越好。

候选池	方法	R@1	R@5	R@20	MRR	MCES@1
质量	SpecMolAlign (alignment seed 42)	47.46	63.51	77.76	55.03	15.37
	候选集合 Transformer (reranker seed 42)	68.74	77.77	82.18	72.87	7.71
分子式	SpecMolAlign (alignment seed 42)	63.10	75.79	84.93	68.86	5.44
	候选集合 Transformer (reranker seed 42)	74.75	82.25	86.89	78.22	3.09

5.3 对比方法与指标

受控基线包括与 reranker 使用同一对齐 checkpoint 的基础检索器, 以及保留全部输入和损失、仅移除候选间自注意力但不匹配参数量的 pointwise reranker。另表列出 GLMR 论文表 1 报告的 JESTR 和 GLMR 结果 [25]。这些外部数字不是受控比较: 我们未在当前代码库中独立复现 JESTR 和 GLMR, 其基础检索器、候选处理、身份/canonicalization 规则与 MCES 实现也未和本文的 exact-SMILES 单正例协议匹配。

评价指标为全部测试查询上的 Recall@1、Recall@5、Recall@20 和 MRR。对每条测试查询, 包括真实目标未进入检索 top-40 的查询, 记 $\hat{m}_n^{(1)}$ 为排序第一的候选。本文报告

$$\text{MCES@1} = \frac{1}{N} \sum_{n=1}^N \tilde{d}_{15}(\hat{m}_n^{(1)}, m_n^+), \quad N = 17,556. \quad (14)$$

其中, $\tilde{d}_{15}$ 是 myopic-MCES 在阈值 15、启用 stronger-bound 选项设置下的输出 [14]。对于足够接近的分子对该值是精确 MCES; 对于较远分子对, 它可能返回阈值或计算得到的下界, 而不是无约束的精确 MCES 距离。因此, 本文数值是经过阈值处理的 myopic MCES, 越低越好。完全相同的 SMILES 字符串直接记为 0。规范实验选择 PULP_CBC_CMD, 日志中没有 MCES worker 失败。canonical 审计中的 Recall/MRR 均值和样本标准差来自固定基础 checkpoint 上的三个 reranker seeds; 跨 alignment 汇总先在每个 checkpoint 内平均 reranker seeds, 再使用三个 alignment-level 配对估计, 二者的样本标准差都不是置信区间。MCES@1 使用 overlap-clean 基础模型和代表性 seed-42 Transformer checkpoint 计算; 这些单 checkpoint 数值不包含随机种子不确定性。

5.4 主要结果

在代表性 seed-42 实验中, 候选集合 Transformer 在质量约束 Recall@1 上带来 21.28 个百分点提升, 在分子式约束场景带来 11.65 个百分点提升; MRR 分别提升 17.84 和 9.36 个百分点。Recall@20 的提升较小, 因为此时主要瓶颈已经变为基础 top-40 召回上界。相对对应的固定 overlap-clean 基础模型, 同一个 seed-42 Transformer 将质量候选 MCES@1 从 15.3681 降低到 7.7057 (49.86%), 将分子式候选 MCES@1 从 5.4389 降低到 3.0913 (43.16%)。

表 3: Zhang 等人 [25] 报告的跨论文背景数字。JESTR/GLMR 未在本项目中独立复现, 也不能与表 2 直接比较; 基础检索器、候选与身份处理以及 MCES 实现均可能不同。

候选池	方法	R@1	R@5	R@20	MRR	MCES@1
质量	JESTR (reported; 未复现)	17.62	40.36	64.76	29.12	15.82
	GLMR (reported; 未复现)	64.17	72.96	78.78	67.82	11.14
分子式	JESTR (reported; 未复现)	11.77	33.26	61.01	22.83	11.73
	GLMR (reported; 未复现)	68.48	78.09	84.22	72.47	5.05

表 4: 本地 exact-target-SMILES 单正例、MassSpecGym supplied-candidate top-40 协议下的分 alignment 内部结果; 该协议不等价于官方 evaluator。学习式行先在每个 alignment 内平均 reranker seeds 42–44。三个 checkpoints 来自两个 source commits, 仅提供描述性敏感性证据, 不构成置信区间、显著性或一般端到端随机种子稳定性结论。Recall@1 和 MRR 均为百分比。

Alignment	候选池	Base R@1	Point. R@1	Trans. R@1	Base MRR	Point. MRR	Trans. MRR
42	质量	47.46	67.44	68.58	55.03	71.79	72.60
42	分子式	63.10	73.97	74.57	68.86	77.64	78.02
43	质量	35.92	66.92	67.19	44.33	70.42	70.58
43	分子式	45.08	69.64	69.30	51.85	72.14	71.96
44	质量	23.91	57.78	57.42	32.26	61.22	60.91
44	分子式	28.73	59.76	59.82	36.87	63.14	63.34

表 3 只记录 GLMR 论文给出的外部数值, 不据此对外部流水线与本文作相对性能排序。匹配比较需要在相同基础检索器、候选列表、身份规则和指标实现下重跑基线; 当前外部数字既不支持方法间性能排序, 也不支持机制归因。

5.5 跨 alignment 与受控组件证据

表 4 保留了 alignment 层级: 先在每个第一阶段 checkpoint 内平均 reranker seeds。两种学习式排序器在 Recall@1 和 MRR 的全部 12 个 alignment-候选-学习模型聚合单元中均优于对应 base。相对地, 对每种候选设置和每项指标, Transformer-Pointwise 差值都只有 2/3 个 alignment 为正。三个 alignment-level 配对估计的均值 $\pm$ 样本标准差为: 质量候选 Recall@1 0.35 ± 0.75 个百分点、MRR 0.22 ± 0.56 个百分点; 分子式候选分别为 0.11 ± 0.47 和 0.13 ± 0.29 个百分点。这些只是描述性汇总, 不是置信区间或显著性检验。三个 checkpoints 使用相同的已分析参数哈希, 但来自两个 source commits; 逐 alignment provenance 已保存在分析工件中。因此, 现有内部结果支持监督残差重排序, 但不支持候选 self-attention 具有跨 checkpoint 稳健独立收益。

在表 5 的 canonical alignment-seed-42 checkpoint 上, 候选集合 Transformer 相对 Pointwise 的平均 Recall@1 在质量和分子式场景分别高 1.14 和 0.60 个百分点, MRR 分别高 0.81 和 0.38 个百分点; 该 checkpoint 内六个同种子 Recall@1 和 MRR 差值均为正。由于 Transformer 还多出约 630 万个可训练参数, 该对比仍无法把候选交互与模型容量增加的影响分离, 而跨 alignment 方向

表 5: 冻结 alignment seed 42 的基础检索器和 cache 后进行的 reranker 与组件比较。Base 行固定；其余行报告 reranker seeds 42–44 的均值 $\pm$ 样本标准差。Recall@1 和 MRR 均为百分比。移除行是围绕预先确定的完整候选集合 Transformer 配置、使用相同 cache 和种子分别训练的审计变体，不用于事后选择主模型。所有数值均采用本地 exact-SMILES 单正例协议，并不等价于官方 evaluator。

方法	质量		分子式	
	R@1	MRR	R@1	MRR
Base	47.46	55.03	63.10	68.86
Pointwise	67.44 $\pm$ 0.74	71.79 $\pm$ 0.66	73.97 $\pm$ 0.59	77.64 $\pm$ 0.49
候选集合 Transformer (完整)	68.58 $\pm$ 0.20	72.60 $\pm$ 0.25	74.57 $\pm$ 0.28	78.02 $\pm$ 0.26
去除残差 shortcut	68.16 $\pm$ 0.06	72.33 $\pm$ 0.06	75.01 $\pm$ 0.54	78.38 $\pm$ 0.42
去除基础分数特征与残差路径	68.07 $\pm$ 0.20	72.28 $\pm$ 0.18	74.39 $\pm$ 0.55	77.93 $\pm$ 0.38
去除排名嵌入	70.12 $\pm$ 0.30	73.75 $\pm$ 0.28	76.62 $\pm$ 0.69	79.38 $\pm$ 0.58
去除乘积/绝对差特征	68.10 $\pm$ 0.85	72.29 $\pm$ 0.66	75.76 $\pm$ 0.55	78.90 $\pm$ 0.38
仅 listwise ($\lambda = 0$)	68.91 $\pm$ 0.76	72.86 $\pm$ 0.46	74.24 $\pm$ 0.25	77.71 $\pm$ 0.25

变化进一步排除了稳健自注意力收益主张。

五项移除行是在同一固定 alignment checkpoint 上进行的描述性组件审计。没有任何移除设置使完整模型在两类候选协议的三个同种子配对中均获得更高 MRR。去除排名嵌入在全部六个候选协议与种子的配对中同时提高 Recall@1 和 MRR：相对完整模型，其质量候选的平均提升分别为 1.54 和 1.15 个百分点，分子式候选分别为 2.05 和 1.36 个百分点。残差 shortcut、显式乘积/绝对差特征和 pairwise loss 的方向随候选协议变化。联合去除基础分数特征与残差路径时，完整模型的平均 MRR 高 0.32 和 0.08 个百分点，且种子级方向混合。这些三种子比较不是显著性检验；本文保留预先确定的完整配置作为报告参照，不在查看结果后把某个移除版本升级为新主模型。

作为较早固定 checkpoint 上单独进行的测试重叠敏感性检查，我们剔除上述 3 条测试查询，保留 17,553 条查询。在两种候选设置和两种 reranker 中，三种子平均 Recall@1 下降 0.0045–0.0055 个百分点，单种子绝对变化最大为 0.0056 个百分点。因此，3 条测试重叠对聚合检索指标的影响可忽略；canonical 表格仍保留官方全部测试查询。

验证重叠审计对模型选择的启示更明显。clean 与较早流水线选择了相同的 alignment epoch (best epoch 16, stop epoch 21)，但 12 组配置中有 9 组 reranker 的 best/stop epoch 组合不同。由于 alignment 也被重新训练，且其测试检索指标发生变化，该对比应解释为端到端流水线敏感性，而不是这 6 条验证查询本身的因果效应。

本文不报告候选顺序或完整 top- K 消融。除上述解析得到的 reranker 参数量外，本文不报告峰值显存、cache 构造时间、reranker latency 或端到端 latency。

6 讨论

式 (2)–(3) 将第一阶段候选覆盖率与列表内部排序能力区分开。当 $k = 1$ 、 $K = 40$ 时，已定义的条件量 $A_{1|40}$ 等于 $R@1/U_{40}$ 。根据表中三种子均值，质量约束场景下，该量从基础检索器的 56.58% 提升到 pointwise 的 80.40% 和候选集合 Transformer 的 81.76%；分子式约束场景对应为 70.69%、82.87% 和 83.54%。

还可以计算可达 top-1 改进空间的恢复比例：

$$H = \frac{R@1_{\text{rerank}} - R@1_{\text{base}}}{U_{40} - R@1_{\text{base}}}. \quad (15)$$

pointwise 与候选集合模型在质量场景下分别恢复 54.86% 和 57.99% 的空间，在分子式场景下分别恢复 41.55% 和 43.85%。pointwise 的增益还分别占候选集合模型相对基础模型总增益的 94.60% 和 94.77%。因此，大部分观测提升已经由当前配置下的监督 pointwise 第二阶段排序器实现，候选集合变体只增加了小幅增量。候选集合模型的 Recall@20 三种子均值分别为 82.20% 和 86.77%，距离 U_{40} 仅 1.68 和 2.49 个百分点；因此，在该 top-40 协议下，第一阶段覆盖率是 Recall@20 的主要剩余限制。组件审计进一步表明，五项设计均未使完整模型在两类候选协议下获得一致的成对 MRR 优势，而去除排名嵌入提高了每一个成对 Recall@1 和 MRR。本文因此把预先确定的完整配置保留为报告参照，把总体增益解释为第二阶段重排序框架的证据，而不解释为残差、特征、排名、损失或注意力组件的独立收益。这些代数重表达和移除比较不是因果估计。在 alignment seeds 42–44 中，尽管第一阶段指标变化明显，两种学习式实现相对各自 base 仍保持较大的描述性优势。这增强了三个已审计运行内的框架级观察；与此同时，混合的 Transformer–Pointwise 方向进一步说明大部分增益不应归因于候选 self-attention。

7 局限性与负责任评估

三个 reranker 随机种子的均值 $\pm$ 样本标准差和 paired-win 次数只是描述性统计，不是置信区间或显著性检验。canonical 表和全部组件移除固定 alignment seed 42。独立的跨 alignment 分析仅覆盖三个内部 checkpoints，它们使用相同的已分析参数哈希但来自两个 source commits，并先在每个 alignment 内聚合 reranker seeds；因此只构成描述性敏感性证据，不是一般端到端随机种子稳定性结论。组件审计既未建立跨 alignment 组件稳定性，也未建立因果组件效应：联合基础分数移除同时改变特征输入和残差路径，去除乘积/绝对差特征的条件仍保留候选间 self-attention；表现更好的无排名嵌入版本既未跨 alignment 测试，也未在查看结果后被选为新主模型。候选集合模型的可训练参数总量还是 pointwise 的 5.26 倍（多 6,304,768 个，约 +426%），因而候选交互与模型容量没有被分离。外部 JESTR 与 GLMR 结果未在相同软件和候选处理下复现；本文不作确定的 SOTA、组件因果贡献或 self-attention 收益声明。

训练专用的正例替换改变了检索列表分布，也不能解决比例为 $1 - U_K$ 的覆盖失败。冻结的完整候选池包含 exact target，因此评价在完整池层面属于闭集，即使目标可能在 top-40 截断后缺失。本文未量化 exact-SMILES 身份规则相对参考二维 InChIKey 规则的影响，因此 Recall/MRR 是明

确的本地协议结果，并不等价于官方 evaluator。精确记录重叠审计也不能排除近重复样本或相关数据来源。模型选择排除审计出的 6 条 train-validation 记录重叠，并保留全部测试查询。当前事后验收环境已锁定版本，并已从显式 Conda/PyPI 锁重建；但历史训练运行没有保留逐包环境证明，因此本文不声称训练可按位重现。2026 年 MassSpecGym 审计预印本还报告了数据泄漏、shortcut learning、实现错误和指标不一致风险，并发布 v1.5 [16]；本文分数与冻结工件和本地协议绑定，不能据此证明与 v1.5 等价。

alignment 采样近似平衡分子标签，而最终指标把每条测试谱图作为一个查询，因此具有重复谱图的分子在聚合指标中权重更高。查询特定候选池上的 Recall 衡量候选优先级，而不等于确认的分子鉴定。已有框架区分结构注释置信度，COSMIC 则研究谱图库缺失结构的注释 [19, 11]。Conformal retrieval 可在 exchangeability 且目标属于候选池等假设下生成具有边际覆盖率的谱图特异预测集 [18]，但该保证不会自动覆盖目标未进入检索 top-40 的情况。本文既未执行概率校准，也不提供 abstention；目标缺失时仍会返回 top-1 候选，实际鉴定仍需要正文实验证据。

最后，分子式约束场景假设分子式可用。谱图塔接收选定峰和前体 m/z ，但不显式使用加合物、仪器或碰撞能量。模型在采集条件迁移、其他检索器与嵌入几何、不同身份规则与候选池构造、更大列表、其他基准和外部分子库上的稳健性未经验证。闭集方法也不能提出所提供候选池之外的结构，即便它避免了自回归生成有效性失败。

8 结论

本文研究并评估 SpecEmbedding-Rerank，一个面向 MS/MS 分子检索的监督、非生成式第二阶段排序器。Recall 和 MRR 使用 MassSpecGym 提供候选文件上的本地 exact-target-SMILES 单正例规则。参考 loader 默认使用二维 InChIKey 等价并可能产生多个正例；该差异影响尚未量化，因此本文结果不等价于官方 evaluator。在该协议下，两种学习式实现跨 alignment seeds 42–44 的 12 个聚合单元均在 Recall@1 和 MRR 上改善对应 base。候选集合 Transformer 在 canonical checkpoint 上相对 pointwise 呈现小幅优势，但对每种候选设置和指标都只有 2/3 个 alignment 方向为正。五项移除设置中没有任何一项使完整模型在 canonical alignment 的两类候选协议下均获得一致的成对 MRR 优势；去除排名嵌入反而提高了全部六个固定 alignment 配对的 Recall@1 和 MRR。最稳健的结论是第二阶段重排序框架的价值，而不是 self-attention 或任一受审计设计的独立收益。另表展示的 JESTR/GLMR 未复现且不可直接比较；匹配外部基线和实测效率仍超出当前证据范围。

参考文献

- [1] Eric Bach, Emma L. Schymanski, and Juho Rousu. Joint structural annotation of small molecules using liquid chromatography retention order and tandem mass spectrometry data. *Nature Machine Intelligence*, 4:1224–1237, 2022.

- [2] Chris Burges, Tal Shaked, Erin Renshaw, Ari Lazier, Matt Deeds, Nicole Hamilton, and Greg Hullender. Learning to rank using gradient descent. In *Proceedings of the 22nd International Conference on Machine Learning*, pages 89–96, 2005.
- [3] Roman Bushuiev, Anton Bushuiev, Niek F. de Jonge, Adamo Young, Fleming Kretschmer, Raman Samusevich, Janne Heirman, Fei Wang, Luke Zhang, Kai Dührkop, et al. MassSpecGym: A benchmark for the discovery and identification of molecules. In *Advances in Neural Information Processing Systems*, volume 37, pages 110010–110027, 2024.
- [4] Zhe Cao, Tao Qin, Tie-Yan Liu, Ming-Feng Tsai, and Hang Li. Learning to rank: From pairwise approach to listwise approach. In *Proceedings of the 24th International Conference on Machine Learning*, pages 129–136, 2007.
- [5] Lu Chen, Bing Xia, Yu Wang, Xia Huang, Yucheng Gu, Wenlin Wu, and Yan Zhou. CMSSP: A contrastive mass spectra-structure pretraining model for metabolite identification. *Analytical Chemistry*, 96(42):16871–16881, 2024.
- [6] Yan Zhou Chen and Soha Hassoun. Learning from all views: A multiview contrastive framework for metabolite annotation. *Analytical Chemistry*, 98(9):6598–6606, 2026.
- [7] Niek F. de Jonge, Joris J. R. Louwen, Elena Chekmeneva, Stephane Camuzeaux, Femke J. Vermeir, Robert S. Jansen, Florian Huber, and Justin J. J. van der Hooft. MS2Query: Reliable and scalable MS2 mass spectra-based analogue search. *Nature Communications*, 14(1):1752, 2023.
- [8] Kai Dührkop, Huibin Shen, Marvin Meusel, Juho Rousu, and Sebastian Böcker. Searching molecular structure databases with tandem mass spectra using CSI:FingerID. *Proceedings of the National Academy of Sciences*, 112(41):12580–12585, 2015.
- [9] Michael Gerlich and Steffen Neumann. MetFusion: Integration of compound identification strategies. *Journal of Mass Spectrometry*, 48(3):291–298, 2013.
- [10] Samuel Goldman, Jeremy Wohlgend, Martin Stražar, Guy Haroush, Ramnik J. Xavier, and Connor W. Coley. Annotating metabolite mass spectra with domain-inspired chemical formula transformers. *Nature Machine Intelligence*, 5(9):965–979, 2023.
- [11] Martin A. Hoffmann, Louis-Félix Nothias, Marcus Ludwig, Markus Fleischauer, Emily C. Gentry, Michael Witting, Pieter C. Dorrestein, Kai Dührkop, and Sebastian Böcker. High-confidence structural annotation of metabolites absent from spectral libraries. *Nature Biotechnology*, 40(3):411–421, 2022.

- [12] Weihua Hu, Bowen Liu, Joseph Gomes, Marinka Zitnik, Percy Liang, Vijay Pande, and Jure Leskovec. Strategies for pre-training graph neural networks. In *International Conference on Learning Representations*, 2020.
- [13] Apurva Kalia, Yan Zhou Chen, Dilip Krishnan, and Soha Hassoun. JESTR: Joint embedding space technique for ranking candidate molecules for the annotation of untargeted metabolomics data. *Bioinformatics*, 41(7):btaf354, 2025.
- [14] Fleming Kretschmer, Jan Seipp, Marcus Ludwig, Gunnar W. Klau, and Sebastian Böcker. Coverage bias in small molecule machine learning. *Nature Communications*, 16:554, 2025.
- [15] Juho Lee, Yoonho Lee, Jungtaek Kim, Adam Kosiorek, Seungjin Choi, and Yee Whye Teh. Set transformer: A framework for attention-based permutation-invariant neural networks. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3744–3753. PMLR, 2019.
- [16] Hongxuan Liu, Roman Bushuiev, Ivy Lightheart, Mrunali Manjrekar, Anton Bushuiev, Magdalena Lederbauer, Filip Jozefov, Yinkai Wang, Soha Hassoun, Josef Sivic, James Taylor, Runzhong Wang, David Healey, Tomáš Pluskal, and Connor W. Coley. MassSpecGym in the wild: Uncovering and correcting evaluation pitfalls in AI-driven molecule discovery, 2026. Preprint.
- [17] Liang Pang, Jun Xu, Qingyao Ai, Yanyan Lan, Xueqi Cheng, and Jirong Wen. SetRank: Learning a permutation-invariant ranking model for information retrieval. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 499–508, 2020.
- [18] Morteza Rakhshaninejad, Gaetan De Waele, Mira Jürgens, and Willem Waegeman. Reliable molecular retrieval from mass spectra using conformal prediction. *Journal of Chemical Information and Modeling*, 66(10):5788–5800, 2026.
- [19] Emma L. Schymanski, Junho Jeon, Rebekka Gulde, Kathrin Fenner, Matthias Ruff, Heinz P. Singer, and Juliane Hollender. Identifying small molecules via high resolution mass spectrometry: Communicating confidence. *Environmental Science & Technology*, 48(4):2097–2098, 2014.
- [20] Michael A. Stravs, Kai Dührkop, Sebastian Böcker, and Nicola Zamboni. MSNovelist: De novo structure generation from mass spectra. *Nature Methods*, 19(7):865–870, 2022.
- [21] Yonglong Tian, Dilip Krishnan, and Phillip Isola. Contrastive multiview coding. In *Computer Vision – ECCV 2020*, pages 776–794. Springer, 2020.

- [22] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [23] Peng Xiong, Hongtao Xu, and Haoran Zheng. Supervised contrastive learning leads to more reasonable spectral embeddings. *Analytical Chemistry*, 97(37):20137–20146, 2025.
- [24] Adamo Young, Hannes Röst, and Bo Wang. Tandem mass spectrum prediction for small molecules using graph transformers. *Nature Machine Intelligence*, 6(4):404–416, 2024.
- [25] Yiwon Zhang, Keyan Ding, Yihang Wu, Xiang Zhuang, Yi Yang, Qiang Zhang, and Huajun Chen. Breaking the modality barrier: Generative modeling for accurate molecule retrieval from mass spectra. In *Proceedings of the Fortieth AAAI Conference on Artificial Intelligence*, volume 40, pages 1561–1569, 2026.