

面向 MS/MS 分子检索的谱图条件相对重排序

匿名作者

摘要

从串联质谱中检索分子结构具有较大挑战，因为质量或分子式约束后的候选池中仍包含大量化学上相近的 hard negatives。本文研究一种直接、非生成式的第二阶段：利用查询谱图比较这些候选，而不是只依赖谱图-分子余弦分数。SpecEmbedding-Rerank 首先对齐峰序列谱图编码器和分子图编码器，并缓存至多 256 个候选的完整供给池；随后先逐候选 coarse 打分，再在 coarse top-40 上计算谱图条件的相对候选偏好。相对偏好由有序 pair 分数与其反向分数之差构成，因此具有反对称性，并对候选列表置换保持等变；新方法不使用检索 rank，也不在训练时插入正例。我们将其与容量匹配、无 rank 的 pointwise 对照比较，并将早期 candidate-set Transformer 保留为历史次级基线。结果在 MassSpecGym 的本地 exact-target-SMILES 单正例协议下报告，同时逐表说明候选覆盖率、seed 统计单位和尚未闭合的比较。参考 loader 允许二维 InChIKey 等价并可能产生多个正例，因此本文数值不等价于官方 evaluator。本文证据用于检验谱图条件的候选关系是否在 coarse 监督排序之外提供可复现信息，而非声称普适的 self-attention 或外部基线优势。

关键词：生物信息学数据挖掘；串联质谱；分子检索；学习排序；多模态表示学习

1 引言

串联质谱 (MS/MS) 被广泛用于代谢组学、天然产物发现和相关生物医学任务中的小分子鉴定。实验谱图只是分子结构在特定实验条件下的部分观测：不同分子可能产生相似碎片，同一分子也可能因仪器、加合物和碰撞能量不同而产生差异明显的谱图。因此，结构注释天然属于一个大规模数据挖掘问题，即根据查询谱图，从受化学条件约束的候选池中检索并排序正确分子。

MassSpecGym 提供了结构不重叠的数据划分，以及标准化的质量约束和分子式约束检索候选池 [3]。现有方法主要尝试缩小谱图和分子之间的模态差距。JESTR 使用 contrastive multiview coding 学习谱图-分子联合空间，并直接按余弦相似度排序候选 [12, 16]。GLMR 则先检索上下文候选，再利用条件语言模型生成 refined molecule，最后根据分子-分子相似度重排候选 [20]。

这两类方法仍留下一个重要的数据挖掘问题。逐候选余弦打分并未在已检索集合上显式训练第二阶段目标；生成式检索则引入自回归解码器，最终排序依赖生成结构的质量和有效性。本文研究监督第二阶段排序器能否区分 hard candidates，以及谱图条件的候选相对比较是否比容量匹配的 pointwise 打分提供额外收益。问题范围有意保持克制：候选池、身份规则和第一阶段 checkpoint 固定，只审计第二阶段机制，而不宣称一种普适检索器。

本文基于 SpecEmbedding 提出的峰序列谱图架构 [18] 构建 SpecEmbedding-Rerank 两阶段框架。第一阶段从零训练该谱图塔，并将其与 GINE 分子图编码器对齐；第二阶段先对完整供给池使用绝对分支，再对 coarse top- K_r 子集使用谱图条件的候选关系。有序 pair 偏好通过反向 pair 分数相减得到，从而无需 rank embedding 即可满足反对称性。训练只使用自然进入候选池的正例，代码不通过插入目标修复截断列表。具有相同绝对分支的 pointwise 模型是主要容量控制，早期 candidate-set Transformer 仅作为历史次级对照。

本文贡献如下：

- 在 MassSpecGym 候选池上实例化并审计直接、非生成式的第二阶段 learning-to-rank，采用完整候选池 coarse 打分和谱图条件的相对候选比较。
- 使机制可检验：相对分支无 rank、具有 pair 反对称性并对候选置换保持等变，训练不执行正例强制插入；容量匹配的 pointwise 对照用于隔离候选关系的贡献。
- 按本地协议报告候选覆盖率和 seed 统计单位，并用保存的嵌入交叉核对官方候选顺序；将新方法 with 历史 Transformer 审计分开，把尚未完成的完整 loader 端到端重编码、外部基线和部署效率问题保留为限制，而不填入不可控比较。

AI 使用披露。 OpenAI Codex 在本稿所有章节中辅助文字起草和语言修改，并在项目过程中辅助代码编辑、实验编排和结果一致性审计。文中实验观测和数值来自所述软件流水线，而非 AI 模型生成。作者已审阅全部 AI 辅助文字与代码，核验技术论述、引用、保存的实验工件和报告结果，并对稿件的准确性、完整性和原创性承担全部责任。

2 相关工作

2.1 结构注释范式

计算式 MS/MS 注释方法的检索对象和排序证据各不相同，候选分数修正也并非本文首次提出。MetFusion 融合 in-silico fragmentation 与谱图库证据 [9]；MS2Query 用五特征随机森林重排 top-2000 MS2DeepScore 匹配 [7]；LC-MS2Struct 将 MS/MS scorer 与保留顺序结合，联合排序同一 LC 分析中的候选 [1]。本文则基于冻结的谱图-分子表示，对 MassSpecGym 的查询特定候选池排序，不依赖谱图库邻居或保留时间证据 [3]。

在结构数据库检索中，CSI:FingerID 和 MIST 从谱图预测分子指纹 [8, 10]。CMSSP 和 JESTR 学习谱图-分子联合空间；MVP 进一步在分子图、指纹、单条谱图和 consensus spectra 间进行对比对齐 [5, 12, 6]。这些方法使用预测指纹分数或跨模态相似度排序候选。SpecEmbedding 研究谱图-谱图表示学习 [18]；本文只复用其峰序列架构，从零开始将其与分子图对齐，并学习已检索 hard-candidate 列表内部的第二阶段顺序。

其他范式采用不同的中间对象：MassFormer 根据分子图预测串联质谱 [19]，MSNovelist 根据 MS/MS 推导的指纹生成结构 [15]，GLMR 则以预检索候选为条件生成分子，再与候选比较 [20]。

表 1: 本文方法与若干相关 MassSpecGym 方法的机制对比。

方法	最终排序信号	候选间交互	生成分子	优化阶段
JESTR	谱图-候选余弦相似度	推理时无	否	InfoNCE; 可选的后期候选正则
GLMR	生成分子-候选余弦相似度	检索候选作为生成器条件	是	dual-path InfoNCE 加自回归生成
本文	pair 特征和检索先验预测的残差分数	候选集合变体可选 self-attention	否	跨模态 InfoNCE 加 listwise/pairwise 重排序

本文的闭集方法不解码结构，也不能返回第一阶段列表外的分子；它直接优化已有候选的分数。

2.2 学习排序与候选集合建模

learning-to-rank 使用候选偏好或完整列表定义监督，而不是把相似度排序作为固定后处理。RankNet 学习 pairwise 偏好，ListNet 则对完整排序列表建立概率模型 [2, 4]。排序函数还可利用竞争候选之间的关系。Set Transformer 为集合输入提供 attention 模块 [13]；SetRank 用 self-attention 建模文档间交互 [14]。本文将这些原则用于缓存的跨模态嵌入，结合显式谱图-候选 pair 特征以及第一阶段分数和排名先验。表 1 将这一查询特定、非生成式第二阶段与若干相关 MassSpecGym 方法并列定位。本文贡献并非 reranking 或 self-attention 本身；残差打分和候选交互是接受评估的设计选项，而不是预先假定的增益来源。

3 问题定义

记 s 为一条 MS/MS 谱图， m^+ 为真实分子， $\mathcal{D}_s$ 为查询对应的质量约束或分子式约束的所提供候选池。基础检索器为每个 $m \in \mathcal{D}_s$ 计算

$$b(s, m) = \text{sim}(f_s(s), f_m(m)), \quad (1)$$

并返回 top- K 列表 $\mathcal{C}_s = (m_1, \dots, m_K)$ 。重排序器学习 $g(s, m_i, \mathcal{C}_s)$ ，使 m^+ 的排名尽可能靠前。由于重排序器无法返回 $\mathcal{C}_s$ 之外的分子，端到端 Recall@ k 的上界为

$$U_K = \frac{1}{N} \sum_{n=1}^N \mathbb{I}[m_n^+ \in \mathcal{C}_{s_n}]. \quad (2)$$

对已进入 top- K 的正例，定义条件排序成功率

$$A_{k|K} = \frac{\sum_{n=1}^N \mathbb{I}[m_n^+ \in \mathcal{C}_{s_n}, \text{rank}_g(m_n^+) \leq k]}{\sum_{n=1}^N \mathbb{I}[m_n^+ \in \mathcal{C}_{s_n}]}, \quad \text{Recall@}k = U_K A_{k|K} \leq U_K. \quad (3)$$




图 1: SpecEmbedding-Rerank 总体流程。面板 1 对齐谱图 Transformer 和分子 GINE；面板 2 使用冻结、缓存的嵌入构造完整候选池；面板 3 先逐候选 coarse 打分，再在 coarse top-40 上计算谱图条件的相对候选偏好，历史 Transformer 仅作为次级对照。虚线表示仅训练时使用的操作；任何阶段均不执行正例强制替换，整个流程不生成分子。

这是指标定义的恒等分解。在固定 top- K cache 时，reranker 只能改变列表内的 $A_{k|K}$ ，不能改变第一阶段覆盖率 U_K 。因此，我们同时报告 U_K 和面向全部查询的排序指标；如果正例不在 top- K 中，该查询记为零，而不是只在成功召回的子集上报告条件准确率。

4 方法

4.1 总体框架

框架包含跨模态对齐、完整候选池检索和相对重排序三个步骤；后者采用监督的 coarse-to-fine 流程。训练 reranker 时冻结谱图和分子编码器，因此两个模态的嵌入可以离线计算并重复使用。

4.2 跨模态基础检索器

谱图编码器沿用 SpecEmbedding 的峰序列架构 [18]，结合正弦 m/z 特征和 Transformer 处理峰的 m/z 与强度序列。在本文实现中，每条谱图最多表示为 100 个 token：第一个 token 是强度设为 2 的前体 m/z ，其后为按强度选出的至多 99 个碎片峰。被选碎片恢复其在源数组中的顺序，强度除以所选碎片的最大强度。谱图编码器只接收这些 m/z -强度 token；加合物、仪器和碰撞能量元数据均不是显式输入。本文从零初始化该谱图塔，并将它用于谱图-分子而非谱图-谱图对齐。分子编码器是基于原子和化学键特征的 GINE [11]，并将 mean-pooled 图特征与显式图规模特征拼接。两个投影头将编码结果映射到统一的 d 维空间：

$$\mathbf{z}_s = \frac{p_s(f_s(s))}{\|p_s(f_s(s))\|_2}, \quad \mathbf{z}_m = \frac{p_m(f_m(m))}{\|p_m(f_m(m))\|_2}. \quad (4)$$

基础模型使用双向跨模态多正例对比损失。具有相同分子标签的谱图和分子均作为正例，从而

避免把同一分子的重复谱图误当成负例。对大小为 B 的 minibatch, 记 $P(i)$ 为与样本 i 具有相同标签的索引集合。使用可学习逆温度尺度 a , 基础 logits 为

$$\ell_{ij} = a \mathbf{z}_{s_i}^\top \mathbf{z}_{m_j}. \quad (5)$$

spectrum-to-molecule 项为

$$\mathcal{L}_{s \rightarrow m} = -\frac{1}{B} \sum_{i=1}^B \frac{1}{|P(i)|} \sum_{j \in P(i)} \log \frac{\exp(\ell_{ij})}{\sum_{k=1}^B \exp(\ell_{ik})}. \quad (6)$$

molecule-to-spectrum 项对 $\ell^\top$ 使用同一表达式, 两项取均值得到 alignment loss。实现令 $a = \exp(u)$ 并将其上限截为 100。推理时, 归一化点积 $b_i = \mathbf{z}_s^\top \mathbf{z}_{m_i}$ 作为基础分数。

4.3 候选构造与训练协议

MassSpecGym 提供按目标分子键控的候选列表; 每条 query 复用其目标分子对应的列表。基础检索器对最多 256 个完整候选打分。新的 coarse-to-fine reranker 先对完整池逐候选打分, 再对 coarse top- $K_r = 40$ 候选执行关系精排。256 和 40 都是本修订中预先固定的设计与计算预算选择; 评价脚本可在不插入正例的情况下截断已保存的完整池。

训练只使用正例自然出现在完整 256 候选池中的 query; 没有自然正例的 query 保留在覆盖率统计中, 但不进入 reranker 损失。训练时打乱候选顺序, 并同步移动候选嵌入和基础分数。新模型完全不使用 rank embedding, cache 兼容字段 `base_ranks` 也不进入其 forward 路径。因此, 任何阶段都不会把正例插入截断列表。目标已存在于全部 32,010 个目标键控源列表中, 完整池 cache 不会扩大文件候选集; 当使用更小的评价截断深度时, 缺失正例只来自第一阶段覆盖率。

4.4 谱图条件的相对候选重排序器

对候选 m_i 保留绝对匹配特征, 但删除检索 rank:

$$\mathbf{x}_i = [\mathbf{z}_s, \mathbf{z}_{m_i}, \mathbf{z}_s \odot \mathbf{z}_{m_i}, |\mathbf{z}_s - \mathbf{z}_{m_i}|, b_i]. \quad (7)$$

绝对分支的 MLP 产生 coarse 分数 $c_i = f_{\text{abs}}(\mathbf{x}_i) + \alpha b_i$ 。对 coarse top- K_r 候选, 令 $u_i = W_m \mathbf{z}_{m_i}$, $v = W_s \mathbf{z}_s$, 并用谱图条件、有向候选差异 $u_i - u_j$ 、其绝对值、基础分数差 $b_i - b_j$ 以及 u_i, u_j 的余弦相似度构造有序关系向量 ρ_{ij} 。共享 MLP 定义有向偏好:

$$p_{ij} = g(\rho_{ij}) - g(\rho_{ji}), \quad p_{ij} = -p_{ji}. \quad (8)$$

关系权重以谱图为条件, 并在有效的非自身候选上归一化。令 $w_{ij} \geq 0$, 最终分数为

$$q_i = c_i + \beta \sum_{j \neq i} w_{ij} p_{ij}. \quad (9)$$

关系分支只在 coarse top- K_r 上计算, 结果再散射回完整候选池。所有运算在候选维度共享, 并使用附着在候选上的 mask; 因此共同置换候选及其特征会以同样方式置换输出分数。式 8 给出与参数取值无关的成对反对称性质。模型不直接使用原始谱峰、SMILES token、前体质量、分子式或采集元数据, 也没有 rank embedding。

容量匹配的 pointwise 对照使用同一绝对分支, 仅移除相对聚合。隐藏宽度 512 时, 相对模型有 1,485,189 个可训练参数, 无 rank 的 pointwise 对照有 1,478,690 个, 差异为 0.44%。通用 candidate-set Transformer 作为次级历史对照保留, 不再作为本文提出的机制。两种模型都不生成分子。

4.5 历史 Candidate-Set Transformer 对照

为便于与早期审计比较, 保留原先含 rank 的 candidate-set Transformer 及其 pointwise 对照。它们不是本修订的正式模型; 其训练期 forcing 和 rank shortcut 只作为历史证据报告, 不用于新的相对模型主张。

对基础排名为 r_i 的候选 m_i , 构造

$$\mathbf{x}_i = [\mathbf{z}_s, \mathbf{z}_{m_i}, \mathbf{z}_s \odot \mathbf{z}_{m_i}, |\mathbf{z}_s - \mathbf{z}_{m_i}|, b_i, \mathbf{e}(\bar{r}_i)], \quad (10)$$

其中 $\mathbf{e}(\bar{r}_i)$ 是可学习排名嵌入。直接嵌入保留模态信息, 元素乘积和绝对差则显式提供对称匹配信号。MLP 将特征投影为

$$\mathbf{h}_i = \text{MLP}(\mathbf{x}_i). \quad (11)$$

两种变体的实际输入仅包括冻结的谱图嵌入、冻结的候选分子嵌入、余弦基础分数、截断后的基础排名嵌入和候选 padding mask。原始谱峰、SMILES token、前体质量或分子式以及采集元数据均不直接输入 reranker。质量与分子式约束只影响候选池构造, 模型也不接收显式的候选-候选结构相似度特征。

候选集合 Transformer 使用不含候选位置编码的 Transformer encoder 在候选之间交换信息 [17]:

$$[\tilde{\mathbf{h}}_1, \dots, \tilde{\mathbf{h}}_K] = \text{Transformer}([\mathbf{h}_1, \dots, \mathbf{h}_K]). \quad (12)$$

padding mask 支持不同长度的候选列表。因此, 在关闭 dropout 的确定性推理时, 将候选及其对应的嵌入、分数和排名共同置换, 输出分数也按同一方式置换; 排名是随候选移动的检索先验, 而不是张量槽位编码。这一设计与置换等变的集合排序表述一致 [13, 14]。pointwise 对照令 $\tilde{\mathbf{h}}_i = \mathbf{h}_i$, 保留相同输入特征、pair MLP、score head、残差路径、训练损失和优化协议, 仅移除构造检索先验之后的学习式候选间交互。该对照没有匹配参数量或模型容量: pointwise 与候选集合 Transformer 分别包含 1,478,690 和 7,783,458 个可训练 reranker 参数。score head 预测修正值 Δ_i , 最终采用残差分数

$$q_i = \alpha b_i + \Delta_i, \quad (13)$$

标量 α 初始化为 1.0, 训练时不施加符号或取值范围约束; Δ_i 同样不受约束。因此, 该 shortcut 使排序器能够直接访问基础分数, 但既不约束 q_i 必须接近 b_i , 也不保证最终排序保留基础顺序。由于 b_i 还是 $\mathbf{x}_i$ 的输入, 残差分支可学习额外的 score-dependent effect, 因而 α 不能单独解释为“保留基础分数的比例”。

4.6 训练目标

记 $\mathcal{B}_L$ 为一个 minibatch 中具有标签的查询集合, V_n 为查询 n 的有效、非 padding 候选索引集合, $y_n \in V_n$ 为其正例索引。实现首先在所有有标签查询上平均 listwise cross-entropy:

$$\mathcal{L}_{\text{list}} = -\frac{1}{|\mathcal{B}_L|} \sum_{n \in \mathcal{B}_L} \log \frac{\exp(q_{ny_n})}{\sum_{i \in V_n} \exp(q_{ni})}. \quad (14)$$

此外, 每个正例都与同一检索列表中的其他全部有效候选进行比较。实现不是先对每个可变长列表分别平均, 而是在整个 minibatch 的所有有效正负对上统一取均值:

$$\mathcal{L}_{\text{pair}} = \frac{\sum_{n \in \mathcal{B}_L} \sum_{i \in V_n \setminus \{y_n\}} \log(1 + \exp(q_{ni} - q_{ny_n} + \gamma))}{\sum_{n \in \mathcal{B}_L} (|V_n| - 1)}. \quad (15)$$

总损失为

$$\mathcal{L} = \mathcal{L}_{\text{list}} + \lambda_{\text{pair}} \mathcal{L}_{\text{pair}} + \lambda_{\text{spec}} \mathcal{L}_{\text{spec}}. \quad (16)$$

对同一 minibatch 中循环错配的谱图 s' , 谱图依赖项比较真实候选在正确和错误 query 下的分数:

$$\mathcal{L}_{\text{spec}} = \text{softplus}(q(s', m^+) - q(s, m^+) + \delta). \quad (17)$$

这是 minibatch 内的依赖约束, 不是因果识别结论。其中 listwise 项是一正例、多候选的 top-one likelihood, 不规定负例之间的完整全序。两个损失都对同一查询内全部 q_i 加上任意相同常数保持不变。因此, 原始 q_i 是相对排序分数而非概率; 本文既未执行也未评价概率校准。

对嵌入宽度 d , 完整池 coarse 打分每条 query 的结构复杂度为 $O(Kd)$, 关系分支在分块计算下为 $O(K_r^2 d)$, 而不是对全部 256 个候选做二次计算。这是结构复杂度说明; 只有在固定硬件基准完成后, 才报告实测 latency、吞吐和峰值显存。

5 实验

5.1 数据集与候选池

我们使用 MassSpecGym 论文发布的划分 [3], 包含 194,119 条训练谱图、19,429 条验证谱图和 17,556 条测试谱图, 共计 231,104 条谱图; 基准论文报告约 29,000 个唯一分子结构。其相似性

感知、结构不重叠构造减少了训练和测试分子之间的近邻结构重叠。

对完整谱图记录签名（峰数组、前体 m/z 、加合物、仪器和碰撞能量）的精确审计未发现跨划分标签分子重复，但有 6 条验证签名和 3 条测试签名与训练签名精确匹配。这 9 个匹配对的标签分子均不相同，且对应评价查询均标记为 `simulation_challenge=true`。本文将其报告为跨划分谱图记录重叠。作为 canonical 配置的 overlap-clean alignment-seed-42 流水线在所有依赖验证集的模型选择阶段排除这 6 条验证谱图，使 reranker 验证查询数变为 19,423；alignment 的验证分子键数从 3,386 降至 3,384。测试阶段仍保留并评价论文发布的全部 17,556 条查询。

实验评估 MassSpecGym 提供的两种候选设置。质量约束候选池使用前体质量和容差窗口；分子式约束候选池假设已知分子式，因此应解释为 formula-conditioned retrieval，而不是完全开放的未知结构注释。冻结候选池至多包含 256 个候选。截断前，测试查询的候选数在质量和分子式场景下平均为 253.88 和 165.75；对应 17,556 条查询中，分别只有 1 条和 3,159 条的候选数少于 40。经过 top-40 截断后，平均候选数为 40.00 和 35.73。

本地 cache 和 evaluator 以 exact target-SMILES equality 定义唯一正例。在官方代码 commit 4f501b3 中，¹参考 loader 默认使用二维 InChIKey 等价规则，可能标出多个正例。因此，本文 Recall 和 MRR 使用所提供候选文件上的本地 exact-target-SMILES 单正例协议；我们还对保存的 17,556 条测试 query 应用了 MassSpecGym 1.3.1 的二维 InChIKey 变换：质量和分子式候选池都没有多正例 query 或身份碰撞，seed-42 relative 指标在两种规则下不变。这是缓存层面的身份审计，不是通过官方 loader 的完整重跑，因此仍保留 local-protocol 标记。alignment 中的多个正例标签同样来自 cache 中的 raw exact-SMILES 标签，而不是二维分子身份标签。图特征没有显式编码原子手性或键立体化学，因此某个立体异构候选在本地协议中可能被标为负例，而二维身份规则可能将其合并；这一模型层面的后果尚未量化。

本地 cache 的候选集合与 MassSpecGym 1.3.1 retrieval JSON 的集合完全一致，但列表顺序不同（质量场景逐列表完全相同的为 0/17,556，分子式场景为 231/17,556）。因此我们重建了官方 JSON 顺序，用保存的 alignment 嵌入重新计算 cosine/Base 排名，并评价 seed-42 的 relative 和 pointwise checkpoint。该官方顺序交叉核验只改变并列次序相关的数值（质量 relative/pointwise R@1 为 50.08/51.63，分子式为 66.80/68.05），不替代三 seed 本地主表：它使用保存的嵌入，没有重新通过完整 official loader 变换或重训 alignment。

5.2 实现细节

对齐模型输出 512 维嵌入。谱图 Transformer 为 4 层、16 个 attention heads、宽度 512；分子 GINE 为 4 层、隐藏宽度 128、dropout 0.2。当前实验不加载已发布的 SpecEmbedding checkpoint，因此跳过仅冻结预训练谱图塔的第一训练阶段，并在后续 alignment 阶段使用 MassSpecGym 训练集端到端优化两个编码塔。alignment 使用 AdamW，batch size 128，学习率 10^{-4} ，weight decay 10^{-4} ，cosine schedule，gradient-norm clipping 为 1，最多 100 个 epoch，early stopping patience 为 5。每个 epoch 对每个唯一分子标签采样 10 次，每次随机选择一条关联谱图。谱图和分子图

¹MassSpecGym reference loader 与 label transform，访问日期：2026-08-01。

增强分别以 0.5 概率启用：谱图增强删除归一化强度低于 0.3 的碎片峰中 20%（向下取整），并进行 $\pm 15\%$ 强度扰动；图增强执行 10% node dropout 和 10% directed edge-entry dropout。验证关闭增强，但在固定随机流下保留关联谱图的随机采样。历史审计将 overlap-clean project-default seed-42 实验及其 cache 定义为 canonical 配置；seed 42 来自项目默认配置，在 43/44 敏感性运行前冻结，且不按测试性能选择。本修订的 no-forcing pilot 则使用当前可用的 pre-overlap-clean alignment checkpoint d4c1f70，单独报告且不声称 overlap-clean 或 alignment seed 稳定性；它不更新历史 canonical 工件 manifest。

reranker 隐藏维度为 512，相对分支维度为 32，pair chunk 为 16，dropout 为 0.1。模型先对 $K = 256$ 的完整候选池打分，再对 coarse top- $K_r = 40$ 使用相对分支。优化器为 AdamW，学习率 10^{-4} ，batch size 16，最多训练 30 个 epoch，并根据验证集 MRR 使用 patience 为 5 的 early stopping。pairwise 与谱图依赖损失的权重和 margin 为 $\lambda_{\text{pair}} = 0.2$ 、 $\lambda_{\text{spec}} = 0.1$ 、 $\gamma = 0.1$ 和 $\delta = 0.1$ 。容量匹配的 pointwise 对照使用相同绝对分支和优化协议，但不做相对聚合；历史 candidate-set Transformer 仅作为次级对照，保留其已记录的 rank-aware 配置。

每项结果工件都列出 alignment checkpoint 和 reranker training seeds。training seed 同时控制初始化、DataLoader 顺序、候选打乱和 dropout，并不是独立的 alignment 重复。训练只使用正例自然存在于完整候选池中的 query；无此标签的 query 从 reranker loss 中排除，但保留在覆盖率统计中。任何 cache 都不插入正例。模型选择不访问测试集；相应运行在 NVIDIA RTX 4090 上完成时才记录为 GPU 结果，CPU smoke test 不作为科学结果。

5.3 代码、数据与工件可用性

匿名补充包提供源码检查、锁定的环境文件、自动化测试和一个小型 CPU 合成 smoke test，但不包含 MassSpecGym 谱图、候选池、训练后的 alignment 或 reranker checkpoint、reranker cache、日志及私有分析工件；因此 smoke test 不能复现论文科学指标。质量和分子式两种候选池分别训练 reranker。pilot 的训练实现提交为 488a04a，逐 query 评估工具提交为 8ce2655；参数哈希、cache 和 checkpoint 指纹记录在内部 pilot manifest 中；该 manifest 不随匿名投稿包提供，release manifest 仅覆盖论文 PDF。早期含 rank Transformer 审计仍由其历史工件记录追踪，不与本 pilot provenance 混合。公开的图特征包括原子符号、度、总氢数、芳香性、环大小分箱、形式电荷；键类型、共轭性、环内标志；以及 $\log(1 + n_{\text{atoms}})$ 、 $\log(1 + n_{\text{bonds}})$ 图规模特征。alignment 投影为 512 维、 $\tau = 0.07$ ；AdamW weight decay 为 10^{-4} 、gradient clipping 为 1；谱图 cache 使用 FP32、分子 cache 使用 FP16。真实数据入口为 run_rerank_pipeline.py，但运行仍需获得上述未随匿名包提供的数据和工件。

5.4 对比方法与指标

受控比较包括同一对齐 checkpoint 的余弦基础检索器、容量匹配且无 rank 的 pointwise coarse 打分器、本文提出的相对 reranker，以及历史 candidate-set Transformer；后者只作为机制基线，不是本文正式方法。JESTR 和 GLMR 仅作为 GLMR 论文中的 reported-only 机制背景 [20]；本文不

表 2: 本地 MassSpecGym 无 forcing 完整候选池 pilot。Base 使用同一 pre-overlap-clean d4c1f70 cache; 学习式结果为 reranker training seeds 42–44 的均值 $\pm$ 样本标准差, 每次使用 5,000 条 query 训练三个 epoch。Recall 和 MRR 采用本地 exact-target-SMILES 单正例协议。

候选池	方法	R@1	R@5	R@20	MRR
质量	SpecMolAlign (完整池, seed 42)	43.78	61.10	75.55	52.19
	容量匹配 pointwise	51.37 $\pm$ 0.54	67.34 $\pm$ 0.39	80.71 $\pm$ 0.55	59.03 $\pm$ 0.44
	相对候选模型	50.98 $\pm$ 0.87	67.06 $\pm$ 0.67	80.49 $\pm$ 0.55	58.71 $\pm$ 0.76
分子式	SpecMolAlign (完整池, seed 42)	58.49	71.50	81.81	64.79
	容量匹配 pointwise	66.65 $\pm$ 1.30	76.76 $\pm$ 0.87	85.33 $\pm$ 0.42	71.66 $\pm$ 1.04
	相对候选模型	66.32 $\pm$ 0.46	76.29 $\pm$ 0.23	85.08 $\pm$ 0.07	71.29 $\pm$ 0.33

展示其外部数值。这些外部结果不是受控比较: 我们未在当前代码库中独立复现 JESTR 和 GLMR, 其基础检索器、候选处理、身份/canonicalization 规则与 MCES 实现也未和本文的 exact-target-SMILES 单正例协议匹配; 本文不展示这些外部数值。

评价指标为全部测试查询上的 Recall@1、Recall@5、Recall@20 和 MRR。新的 pilot 使用同一 pre-overlap-clean alignment checkpoint、5,000 条训练 query 和三个 reranker training seeds (42–44); 均值和样本标准差表示 seed 离散度, 不是独立 alignment 重复。seed-42 的逐 query paired bootstrap 使用保存的预测和 2,000 次确定性重采样。新的 pilot 不重新计算 MCES; 早期经过阈值处理的 myopic-MCES 审计仍作为独立的单 checkpoint 工件保留。

5.5 主要结果

两种学习式模型在两个候选池都超过完整池 Base。三个 seed 聚合中, pointwise 在 R@1 和 MRR 略高于 relative (质量: 51.37 对 50.98、0.5903 对 0.5871; 分子式: 66.65 对 66.32、0.7166 对 0.7129)。同一 256 候选 cache 的评价时 K 敏感性显示, 质量场景 relative/pointwise 在 $K = 20$ 为 80.49/80.71、 $K = 40$ 为 86.13/86.03、 $K = 80$ 为 93.45/93.38; 这些不是按 K 重新训练的结果。seed-42 paired bootstrap 中, 质量 relative 相对 Base 的 R@1 差为 6.30 个百分点 (95% CI: 5.69–6.93), MRR 差为 0.0576 (0.0530–0.0625)。新的 pilot 未计算 MCES; 历史单 checkpoint MCES 审计仍单独保留。

信息来源与机制审计。 在同一 seed-42 pilot 中, 仅使用 base score 的对照在质量/分子式场景的 R@1/MRR 为 43.78%/0.5219 和 58.49%/0.6479, 与 Base 相同; 仅使用 embedding 的绝对打分器为 50.07%/0.5808 和 66.13%/0.7110; 加入 base-score 但不使用相对分支为 50.07%/0.5798 和 66.28%/0.7141。完整 relative 模型为 50.08%/0.5795 和 66.80%/0.7161。仅使用候选分子信息的对照为 45.00%/0.5245 和 52.73%/0.5960, 弱于含谱图条件的变体。移除分子关系、谱图条件或反对称 pair 后两个候选池方向不一致; 这些单 seed 对照支持的是信息来源分析, 而不是组件因果排序。

JESTR 和 GLMR 保留为 reported-only、未复现且不可直接比较的机制背景; 本文不再复现其数值表, 也不据此推断相对排名。

困难候选分层。 在 seed-42 本地 query 分析中, relative 的增益集中在基础排序器未能解决的 query。基础排名为 2-5/6-20 时, relative 相对 Base 的 R@1 增益在质量场景为 +42.17/+23.02 个百分点, 分子式场景为 +52.72/+30.06 个百分点; 当基础 top-1 的 Morgan 相似度低于 0.25 时, 增益分别为 +24.59/+35.92 个百分点。基础排名为 1 或 top-1 相似度至少为 0.5 时则下降 (质量 -13.28/-11.86, 分子式 -5.41/-3.65)。这些是本地协议下 seed-42 的描述性分层, 不是相对模块的因果或显著性证据。

历史审计边界。 早期含 rank 的 Transformer 结果使用旧的 top-40 cache 和仅训练期正例替换。它们仍保存在内部分析工件中以便追溯, 但不是当前无 rank、无 forcing 方法的测量, 也不用于当前主张; 早期的多种子和跨 alignment 汇总不能被理解为相对模块的证据。

6 讨论

新的完整池 pilot 将候选覆盖与列表内排序分开。保存的完整池上界按构造为 100%, 而评价时截断到 top-40 后质量候选上界为 82.15%。三个 reranker seeds 中两种模型都超过 Base; pointwise 在主要 R@1/MRR 汇总略强, relative 在不同 cutoff 并非始终更好。保存的 seed-42 预测还给出 RTX 4090 仅前向测量: 质量 relative 为 0.083 ms/query、峰值分配 302 MB, pointwise 为 0.030 ms/query、244 MB (分子式分别为 0.076/0.029 ms 和 302/244 MB)。这些是实现审计, 不构成效率优越性结论。

质量候选的 spectrum-shuffle 审计使相对模型降为 45.05% Recall@1 和 0.5358 MRR, 仍高于 Base, 但明显低于正确配对的相对结果。这说明模型并非完全不依赖谱图; 然而打乱谱图后仍保留的性能也表明候选与基础分数路径贡献显著。因此, 不能将 pointwise 到 relative 的差异归因于候选关系的因果收益。下方历史 Transformer 结果仅作为旧设计审计保留, 不与本 pilot 合并。

官方顺序交叉核验使用发布的候选 JSON 和保存的 alignment 嵌入, 但没有通过新建的 official loader 重新编码谱图/分子, 也没有重训第一阶段。因此它不能证明另行重建的 loader、不同候选来源或外部方法的端到端等价性。

JESTR/GLMR 仍为 reported-only, 未独立复现。

7 局限性与负责任评估

新的主要证据使用 194,119 条可用训练 query 中的 5,000 条、训练三个 epoch, 以及同一 alignment checkpoint 的三个 reranker training seeds。这不是 alignment 层级或端到端 seed 稳定性; 逐 query bootstrap 也不替代独立重训。二维 InChIKey 审计在保存的测试 cache 中未发现身份碰撞, 但不是官方 loader 的完整重跑; 外部基线和候选感知 alignment 重训仍不在范围内。

无 forcing cache 只保留 MassSpecGym 文件提供的候选。目标若不在评价截断深度内, reranker 无法恢复; 闭集模型也不能提出候选池之外的结构。候选关系只在 coarse top-40 上计算, 因此结

论不扩展到其它 cutoff 或开放分子库。spectrum-shuffle 是 batch 内依赖审计，不是因果或不变性保证。

匿名补充包包含源码检查、锁定环境、测试和合成 smoke test，但不含真实数据、候选文件、cache、checkpoint、日志或 pilot 结果工件。匹配的外部基线和候选感知 alignment 重训仍不在范围内。报告的 latency/显存是固定硬件前向审计，不是端到端吞吐或部署保证。

谱图塔不接收加合物、仪器或碰撞能量元数据，分子式条件也假设公式已知。向其它采集条件、候选构造、身份规则、基准或更大候选列表迁移尚未测试。历史 forced-positive Transformer 结果与新方法分开保存，不能替代新方法的证据边界。

8 结论

本文提出 SpecEmbedding-Rerank：一种无 rank、无 forcing 的第二阶段排序器，将完整候选池 coarse 打分与谱图条件的相对候选偏好结合。在本地 exact-target-SMILES 协议的三个 reranker training seeds 中，relative 和容量匹配 pointwise 都改善质量和分子式场景的完整池 Base；pointwise 在主要 R@1/MRR 汇总略强，spectrum-shuffle 审计也显示候选/base-score 路径贡献显著。因此，当前证据支持该工程框架及其明确的证据边界，但尚未建立 relative 模块独立且普遍稳健的收益。二维 InChIKey cache 审计未发现身份碰撞，但官方 loader 等价性和外部基线比较仍不作主张。

参考文献

- [1] Eric Bach, Emma L. Schymanski, and Juho Rousu. Joint structural annotation of small molecules using liquid chromatography retention order and tandem mass spectrometry data. *Nature Machine Intelligence*, 4(12):1224–1237, 2022.
- [2] Chris Burges, Tal Shaked, Erin Renshaw, Ari Lazier, Matt Deeds, Nicole Hamilton, and Greg Hullender. Learning to rank using gradient descent. In *Proceedings of the 22nd International Conference on Machine Learning*, pages 89–96, 2005.
- [3] Roman Bushuiev, Anton Bushuiev, Niek F. de Jonge, Adamo Young, Fleming Kretschmer, Raman Samusevich, Janne Heirman, Fei Wang, Luke Zhang, Kai Dührkop, Marcus Ludwig, Nils A. Haupt, Apurva Kalia, Corinna Brungs, Robin Schmid, Russell Greiner, Bo Wang, David S. Wishart, Li-Ping Liu, Juho Rousu, Wout Bittremieux, Hannes Röst, Tytus D. Mak, Soha Hassoun, Florian Huber, Justin J. J. van der Hooft, Michael A. Stravs, Sebastian Böcker, Josef Sivic, and Tomáš Pluskal. MassSpecGym: A benchmark for the discovery and identification of molecules. In *Advances in Neural Information Processing Systems*, volume 37, pages 110010–110027, 2024.

- [4] Zhe Cao, Tao Qin, Tie-Yan Liu, Ming-Feng Tsai, and Hang Li. Learning to rank: From pairwise approach to listwise approach. In *Proceedings of the 24th International Conference on Machine Learning*, pages 129–136, 2007.
- [5] Lu Chen, Bing Xia, Yu Wang, Xia Huang, Yucheng Gu, Wenlin Wu, and Yan Zhou. CMSSP: A contrastive mass spectra-structure pretraining model for metabolite identification. *Analytical Chemistry*, 96(42):16871–16881, 2024.
- [6] Yan Zhou Chen and Soha Hassoun. Learning from all views: A multiview contrastive framework for metabolite annotation. *Analytical Chemistry*, 98(9):6598–6606, 2026.
- [7] Niek F. de Jonge, Joris J. R. Louwen, Elena Chekmeneva, Stephane Camuzeaux, Femke J. Vermeir, Robert S. Jansen, Florian Huber, and Justin J. J. van der Hooft. MS2Query: Reliable and scalable MS2 mass spectra-based analogue search. *Nature Communications*, 14(1):1752, 2023.
- [8] Kai Dührkop, Huibin Shen, Marvin Meusel, Juho Rousu, and Sebastian Böcker. Searching molecular structure databases with tandem mass spectra using CSI:FingerID. *Proceedings of the National Academy of Sciences*, 112(41):12580–12585, 2015.
- [9] Michael Gerlich and Steffen Neumann. MetFusion: Integration of compound identification strategies. *Journal of Mass Spectrometry*, 48(3):291–298, 2013.
- [10] Samuel Goldman, Jeremy Wohllwend, Martin Stražar, Guy Haroush, Ramnik J. Xavier, and Connor W. Coley. Annotating metabolite mass spectra with domain-inspired chemical formula transformers. *Nature Machine Intelligence*, 5(9):965–979, 2023.
- [11] Weihua Hu, Bowen Liu, Joseph Gomes, Marinka Zitnik, Percy Liang, Vijay Pande, and Jure Leskovec. Strategies for pre-training graph neural networks. In *International Conference on Learning Representations*, 2020.
- [12] Apurva Kalia, Yan Zhou Chen, Dilip Krishnan, and Soha Hassoun. JESTR: Joint embedding space technique for ranking candidate molecules for the annotation of untargeted metabolomics data. *Bioinformatics*, 41(7):btaf354, 2025.
- [13] Juho Lee, Yoonho Lee, Jungtaek Kim, Adam Kosiorek, Seungjin Choi, and Yee Whye Teh. Set transformer: A framework for attention-based permutation-invariant neural networks. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3744–3753. PMLR, 2019.
- [14] Liang Pang, Jun Xu, Qingyao Ai, Yanyan Lan, Xueqi Cheng, and Jirong Wen. SetRank: Learning a permutation-invariant ranking model for information retrieval. In *Proceedings of*

- the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 499–508, 2020.
- [15] Michael A. Stravs, Kai Dührkop, Sebastian Böcker, and Nicola Zamboni. MSNovelist: De novo structure generation from mass spectra. *Nature Methods*, 19(7):865–870, 2022.
- [16] Yonglong Tian, Dilip Krishnan, and Phillip Isola. Contrastive multiview coding. In *Computer Vision – ECCV 2020*, volume 12356 of *Lecture Notes in Computer Science*, pages 776–794, Cham, 2020. Springer.
- [17] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008, 2017.
- [18] Peng Xiong, Hongtao Xu, and Haoran Zheng. Supervised contrastive learning leads to more reasonable spectral embeddings. *Analytical Chemistry*, 97(37):20137–20146, 2025.
- [19] Adamo Young, Hannes Röst, and Bo Wang. Tandem mass spectrum prediction for small molecules using graph transformers. *Nature Machine Intelligence*, 6(4):404–416, 2024.
- [20] Yiwen Zhang, Keyan Ding, Yihang Wu, Xiang Zhuang, Yi Yang, Qiang Zhang, and Huajun Chen. Breaking the modality barrier: Generative modeling for accurate molecule retrieval from mass spectra. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(2):1561–1569, 2026.