

固定候选池上的 MS/MS 分子非生成式监督重排序

匿名作者

摘要

从串联质谱中检索分子结构具有较大挑战，因为质量或分子式约束后的候选池中仍包含大量化学上相近的 hard negatives。本文研究监督式、非生成式的第二阶段重排序能否改善固定候选列表，而不生成新的结构。SpecEmbedding-Rerank 首先对齐峰序列谱图编码器和分子图编码器，并复用至多 256 个所提供候选的保存嵌入；随后先逐候选 coarse 打分，再在 coarse top-40 上计算谱图条件的相对候选偏好。相对偏好由有序 pair 分数与其反向分数之差构成，因此具有反对称性，并对候选列表置换保持等变，但 coarse 选择中的并列项处理可能影响这一性质。模型不使用检索 rank。我们将其与参数近似匹配的 pointwise 对照比较。在 MassSpecGym 的质量和分子式候选池上，保存嵌入的 top-40 评价显示两种监督重排序器都改善了基础检索器。这些运行最多使用 20,000 条训练 query，训练时插入缺失正例，尚不能验证全量训练、top-256、全 split 无 forcing 配置。relative 与 pointwise 的排序依赖候选协议和指标。因此，本文将相对分支作为形式化的候选交互机制并研究其经验边界，而不声称关系模块或外部基线具有普遍优势。本文方法是闭集、非生成式方法：它只能改善已有候选的顺序，不能恢复候选池之外的分子。

关键词：生物信息学数据挖掘；串联质谱；分子检索；学习排序；多模态表示学习

1 引言

串联质谱 (MS/MS) 被广泛用于代谢组学、天然产物发现和相关生物医学任务中的小分子鉴定。实验谱图只是分子结构在特定实验条件下的部分观测：不同分子可能产生相似碎片，同一分子也可能因仪器、加合物和碰撞能量不同而产生差异明显的谱图。因此，结构注释天然属于一个大规模数据挖掘问题，即根据查询谱图，从受化学条件约束的候选池中检索并排序正确分子。

MassSpecGym 提供了结构不重叠的数据划分，以及标准化的质量约束和分子式约束检索候选池 [3]。现有方法主要尝试缩小谱图和分子之间的模态差距。JESTR 使用 contrastive multiview coding 学习谱图-分子联合空间，并直接按余弦相似度排序候选 [12, 16]。GLMR 则先检索上下文候选，再利用条件语言模型生成 refined molecule，最后根据分子-分子相似度重排候选 [20]。

这两类方法仍留下一个重要的数据挖掘问题。逐候选余弦打分并未在已检索集合上显式训练第二阶段目标；生成式检索则引入自回归解码器，最终排序依赖生成结构的质量和有效性。因此，本文回答两个相互关联的问题：监督第二阶段排序器能否区分 hard candidates，以及谱图条件的候选相对比较是否比容量匹配的 pointwise 打分提供额外收益。前一个问题检验学习式列表重排本身是否 valuable，后一个问题检验该收益是否必须依赖候选交互。在每组配对比较中，候选池和第一阶段

表示保持固定，使比较集中于第二阶段排序机制；跨 alignment 矩阵则单独描述不同保存的第一阶段 checkpoint 带来的敏感性。

本文基于 SpecEmbedding 提出的峰序列谱图架构 [18] 构建 SpecEmbedding-Rerank 两阶段框架。第一阶段从零训练该谱图塔，并将其与 GINE 分子图编码器对齐；第二阶段先对完整供给池使用绝对分支，再对 coarse top- K_r 子集使用谱图条件的候选关系。有序 pair 偏好通过反向 pair 分数相减得到，从而无需 rank embedding 即可满足反对称性。默认 pipeline 只使用自然正例，但已报告的 top-40 矩阵复用了训练时插入正例的历史缓存。具有相同绝对分支的 pointwise 模型是主要容量控制，早期 candidate-set Transformer 仅作为历史参考。

本文贡献如下：

- 在 MassSpecGym 候选池上提出直接、闭集、非生成式的第二阶段 learning-to-rank 框架，采用完整候选池 coarse 打分和谱图条件的相对候选比较。
- 定义无 rank、具有 pair 反对称性与候选置换等变性的相对分支，并设置参数近似匹配的 pointwise 对照。
- 在质量和分子式候选协议、三个保存的 alignment checkpoint 以及 30 次 relative 模块消融矩阵上系统考察该框架：监督重排序改善基础检索器，但当前证据尚不能建立相对候选交互相对 pointwise 打分的独立优势。

AI 使用披露。 OpenAI Codex 在本稿所有章节中辅助文字起草和语言修改，并在项目过程中辅助代码编辑、实验编排和结果一致性审计。文中实验观测和数值来自所述软件流水线，而非 AI 模型生成。作者已审阅全部 AI 辅助文字与代码，核验技术论述、引用、保存的实验工件和报告结果，并对稿件的准确性、完整性和原创性承担全部责任。

2 相关工作

2.1 结构注释范式

计算式 MS/MS 注释方法的检索对象和排序证据各不相同，候选分数修正也并非本文首次提出。MetFusion 融合 in-silico fragmentation 与谱图库证据 [9]；MS2Query 用五特征随机森林重排 top-2000 MS2DeepScore 匹配 [7]；LC-MS2Struct 将 MS/MS scorer 与保留顺序结合，联合排序同一 LC 分析中的候选 [1]。本文则基于冻结的谱图-分子表示，对 MassSpecGym 的查询特定候选池排序，不依赖谱图库邻居或保留时间证据 [3]。

在结构数据库检索中，CSI:FingerID 和 MIST 从谱图预测分子指纹 [8, 10]。CMSSP 和 JESTR 学习谱图-分子联合空间；MVP 进一步在分子图、指纹、单条谱图和 consensus spectra 间进行对比对齐 [5, 12, 6]。这些方法使用预测指纹分数或跨模态相似度排序候选。SpecEmbedding 研究谱图-谱图表示学习 [18]；本文只复用其峰序列架构，从零开始将其与分子图对齐，并学习已检索 hard-candidate 列表内部的第二阶段顺序。

表 1: 本文方法与若干相关 MassSpecGym 方法的机制对比。

方法	最终排序信号	候选间交互	生成分子	优化阶段
JESTR	谱图-候选余弦相似度	推理时无	否	InfoNCE; 可选的后期候选正则
GLMR	生成分子-候选余弦相似度	检索候选作为生成器条件	是	dual-path InfoNCE 加自回归生成
本文	pair 特征和检索先验预测的残差分数	谱图条件的反对称候选对交互	否	跨模态 InfoNCE 加 listwise/pairwise 重排序

其他范式采用不同的中间对象: MassFormer 根据分子图预测串联质谱 [19], MSNovelist 根据 MS/MS 推导的指纹生成结构 [15], GLMR 则以预检索候选为条件生成分子, 再与候选比较 [20]。本文的闭集方法不解码结构, 也不能返回第一阶段列表外的分子; 它直接优化已有候选的分数。

2.2 学习排序与候选集合建模

learning-to-rank 使用候选偏好或完整列表定义监督, 而不是把相似度排序作为固定后处理。RankNet 学习 pairwise 偏好, ListNet 则对完整排序列表建立概率模型 [2, 4]。排序函数还可利用竞争候选之间的关系。Set Transformer 为集合输入提供 attention 模块 [13]; SetRank 用 self-attention 建模文档间交互 [14]。本文将这些原则用于缓存的跨模态嵌入, 结合显式谱图-候选 pair 特征以及第一阶段分数和排名先验。表 1 将这一查询特定、非生成式第二阶段与若干相关 MassSpecGym 方法并列定位。本文贡献并非 reranking 或 self-attention 本身; 残差打分和候选交互是接受评估的设计选项, 而不是预先假定的增益来源。

3 问题定义

记 s 为一条 MS/MS 谱图, m^+ 为真实分子, $\mathcal{D}_s$ 为查询对应的质量约束或分子式约束的所提供候选池。基础检索器为每个 $m \in \mathcal{D}_s$ 计算

$$b(s, m) = \text{sim}(f_s(s), f_m(m)), \quad (1)$$

并返回 top- K 列表 $\mathcal{C}_s = (m_1, \dots, m_K)$ 。重排序器学习 $g(s, m_i, \mathcal{C}_s)$, 使 m^+ 的排名尽可能靠前。由于重排序器无法返回 $\mathcal{C}_s$ 之外的分子, 端到端 Recall@ k 的上界为

$$U_K = \frac{1}{N} \sum_{n=1}^N \mathbb{I}[m_n^+ \in \mathcal{C}_{s_n}]. \quad (2)$$

对已进入 top- K 的正例, 定义条件排序成功率




图 1: SpecEmbedding-Rerank 的默认 top-256 配置。面板 1 对齐谱图 Transformer 和分子 GINE; 面板 2 使用冻结、缓存的嵌入构造完整候选池; 面板 3 先逐候选 coarse 打分, 再在 coarse top-40 上计算谱图条件的相对候选偏好, 历史 Transformer 仅作为历史参考。虚线表示仅训练时使用的操作。该默认配置不强制插入正例, 也不生成分子; 已报告矩阵使用训练时插入正例的历史 top-40 缓存。

$$A_{k|K} = \frac{\sum_{n=1}^N \mathbb{I}[m_n^+ \in \mathcal{C}_{s_n}, \text{rank}_g(m_n^+) \leq k]}{\sum_{n=1}^N \mathbb{I}[m_n^+ \in \mathcal{C}_{s_n}]}, \quad \text{Recall}@k = U_K A_{k|K} \leq U_K. \quad (3)$$

这是指标定义的恒等分解。在固定 top- K cache 时, reranker 只能改变列表内的 $A_{k|K}$, 不能改变第一阶段覆盖率 U_K 。因此, 我们同时报告 U_K 和面向全部查询的排序指标; 如果正例不在 top- K 中, 该查询记为零, 而不是只在成功召回的子集上报告条件准确率。

4 方法

4.1 总体框架

框架包含跨模态对齐、完整候选池检索和相对重排序三个步骤; 后者采用监督的 coarse-to-fine 流程。训练 reranker 时冻结谱图和分子编码器, 因此两个模态的嵌入可以离线计算并重复使用。

4.2 跨模态基础检索器

谱图编码器沿用 SpecEmbedding 的峰序列架构 [18], 结合正弦 m/z 特征和 Transformer 处理峰的 m/z 与强度序列。在本文实现中, 每条谱图最多表示为 100 个 token: 第一个 token 是强度设为 2 的前体 m/z , 其后为按强度选出的至多 99 个碎片峰。被选碎片恢复其在源数组中的顺序, 强度除以所选碎片的最大强度。谱图编码器只接收这些 m/z -强度 token; 加合物、仪器和碰撞能量元数据均不是显式输入。本文从零初始化该谱图塔, 并将它用于谱图-分子而非谱图-谱图对齐。分子编码器是基于原子和化学键特征的 GINE [11], 并将 mean-pooled 图特征与显式图规模特征拼接。两个投影头将编码结果映射到统一的 d 维空间:

$$\mathbf{z}_s = \frac{p_s(f_s(s))}{\|p_s(f_s(s))\|_2}, \quad \mathbf{z}_m = \frac{p_m(f_m(m))}{\|p_m(f_m(m))\|_2}. \quad (4)$$

基础模型使用双向跨模态多正例对比损失。具有相同分子标签的谱图和分子均作为正例，从而避免把同一分子的重复谱图误当成负例。对大小为 B 的 minibatch，记 $P(i)$ 为与样本 i 具有相同标签的索引集合。使用可学习逆温度尺度 a ，基础 logits 为

$$\ell_{ij} = a \mathbf{z}_{s_i}^\top \mathbf{z}_{m_j}. \quad (5)$$

spectrum-to-molecule 项为

$$\mathcal{L}_{s \rightarrow m} = -\frac{1}{B} \sum_{i=1}^B \frac{1}{|P(i)|} \sum_{j \in P(i)} \log \frac{\exp(\ell_{ij})}{\sum_{k=1}^B \exp(\ell_{ik})}. \quad (6)$$

molecule-to-spectrum 项对 $\ell^\top$ 使用同一表达式，两项取均值得到 alignment loss。实现令 $a = \exp(u)$ 并将其上限截为 100。推理时，归一化点积 $b_i = \mathbf{z}_s^\top \mathbf{z}_{m_i}$ 作为基础分数。

4.3 候选构造与训练协议

MassSpecGym 提供按目标分子键控的候选列表；每条 query 复用其目标分子对应的列表。基础检索器对最多 256 个候选打分。默认 coarse-to-fine 配置保留完整池逐候选打分，再对 coarse top- $K_r = 40$ 做关系精排。已报告的主矩阵和消融则使用保存的 Base top-40 列表，关系分支最多处理 40 个候选。

默认 pipeline 不插入正例：无标签 query 保留在 coverage 统计中，但不进入训练损失。已报告的 top-40 运行使用历史训练缓存，正例缺失时替换最后一个候选以插入正例；验证/测试均不 forcing，缺失正例计零分。该历史训练协议与默认 no-forcing 配置、独立 top-256 pilot 必须区分。训练时候选嵌入、分数和标签同步打乱。relative 与无 rank 对照都不使用检索 rank 特征，relative forward 忽略兼容字段 `base_ranks`。

4.4 谱图条件的相对候选重排序器

对候选 m_i 保留绝对匹配特征，但删除检索 rank：

$$\mathbf{x}_i = [\mathbf{z}_s, \mathbf{z}_{m_i}, \mathbf{z}_s \odot \mathbf{z}_{m_i}, |\mathbf{z}_s - \mathbf{z}_{m_i}|, b_i]. \quad (7)$$

绝对分支的 MLP 产生 coarse 分数 $c_i = f_{\text{abs}}(\mathbf{x}_i) + \alpha b_i$ 。对 coarse top- K_r 候选，令 $u_i = W_m \mathbf{z}_{m_i}$ ， $v = W_s \mathbf{z}_s$ ，并用谱图条件、有向候选差异 $u_i - u_j$ 、其绝对值、基础分数差 $b_i - b_j$ 以及 u_i, u_j 的余弦相似度构造有序关系向量 ρ_{ij} 。共享 MLP 定义有向偏好：

$$p_{ij} = g(\rho_{ij}) - g(\rho_{ji}), \quad p_{ji} = -p_{ij}. \quad (8)$$

关系权重以谱图为条件，并在有效的非自身候选上归一化。令 $w_{ij} \geq 0$ ，最终分数为

$$q_i = c_i + \beta \sum_{j \neq i} w_{ij} p_{ij}. \quad (9)$$

关系分支只在 coarse top- K_r 上计算, 结果再散射回完整候选池。所有运算在候选维度共享, 并使用附着在候选上的 mask; 因此共同置换候选及其特征会以同样方式置换输出分数, 但 coarse top- K_r 选择中的 tie 处理可能影响这一过程。式 8 给出与参数取值无关的原始 pair 偏好反对称性; 式 9 中的加权贡献不要求反对称, 因为 w_{ij} 与 w_{ji} 可以不同。模型不直接使用原始谱峰、SMILES token、前体质量、分子式或采集元数据, 也没有 rank embedding。

结构解释。 反向 pair 分数之差使一个有序候选对只有一个偏好方向: 交换 i 和 j 时, 原始 pair 偏好 p_{ij} 只改变符号。这种归纳偏置适合表达“对当前谱图而言候选 i 优于候选 j ”这样的局部判断, 也与训练目标中的 pairwise 项相容。候选维度共享运算则在列表层面施加相应的置换等变性。但这是函数类别的结构性质, 不是性能保证: 成对反对称本身不能排除三个或更多候选之间的循环偏好, 不能证明 hard-negative discrimination 更好, 也不能推出相对模型优于 pointwise 对照。这些问题仍需要进一步受控实验检验。

当前实现提供显式的 `pair_mode` 控制。论文报告的 relative 模型使用 antisymmetric 模式, 即实现式 8; directed 模式保留同一个有序偏好网络, 但省略反向 pair 相减, 作为受控实现入口, 其结果见表 4。旧 checkpoint 缺少 `pair_mode` 时, 按原 `use_antisymmetric` 布尔字段保留既有语义。

参数近似匹配的 pointwise 对照使用同一绝对分支, 仅移除相对聚合。隐藏宽度 512 时, 相对模型有 1,485,189 个可训练参数, 无 rank 的 pointwise 对照有 1,478,690 个, 差异为 0.44%。通用 candidate-set Transformer 作为历史参考保留, 不再作为本文提出的机制。两种模型都不生成分子。

4.5 历史 Candidate-Set Transformer 参考

为提供背景, 保留原先含 rank embedding 和候选 self-attention 的 Candidate-Set Transformer [17] 作为历史参考。两套历史运行均在训练时 forcing, 但模型配置不同; 详细区别见 Appendix B, 且不与当前主表作数值比较。

4.6 训练目标

记 $\mathcal{B}_L$ 为一个 minibatch 中具有标签的查询集合, V_n 为查询 n 的有效、非 padding 候选索引集合, $y_n \in V_n$ 为其正例索引。实现首先在所有有标签查询上平均 listwise cross-entropy:

$$\mathcal{L}_{\text{list}} = -\frac{1}{|\mathcal{B}_L|} \sum_{n \in \mathcal{B}_L} \log \frac{\exp(q_{ny_n})}{\sum_{i \in V_n} \exp(q_{ni})}. \quad (10)$$

此外, 每个正例都与同一检索列表中的其他全部有效候选进行比较。实现不是先对每个可变量列表分别平均, 而是在整个 minibatch 的所有有效正负对上统一取均值:

$$\mathcal{L}_{\text{pair}} = \frac{\sum_{n \in \mathcal{B}_L} \sum_{i \in V_n \setminus \{y_n\}} \log(1 + \exp(q_{ni} - q_{ny_n} + \gamma))}{\sum_{n \in \mathcal{B}_L} (|V_n| - 1)}. \quad (11)$$

总损失为

$$\mathcal{L} = \mathcal{L}_{\text{list}} + \lambda_{\text{pair}} \mathcal{L}_{\text{pair}} + \lambda_{\text{spec}} \mathcal{L}_{\text{spec}}. \quad (12)$$

对同一 minibatch 中循环错配的谱图 s' ，谱图依赖项比较真实候选在正确和错误 query 下的分数：

$$\mathcal{L}_{\text{spec}} = \text{softplus}(q(s', m^+) - q(s, m^+) + \delta). \quad (13)$$

这是 minibatch 内的依赖约束，不是因果识别结论。其中 listwise 项是一正例、多候选的 top-one likelihood，不规定负例之间的完整全序。两个损失都对同一查询内全部 q_i 加上任意相同常数保持不变。因此，原始 q_i 是相对排序分数而非概率；本文既未执行也未评价概率校准。

对嵌入宽度 d ，完整池 coarse 打分每条 query 的结构复杂度为 $O(Kd)$ ，关系分支在分块计算下为 $O(K_r^2 d)$ ，而不是对全部 256 个候选做二次计算。这是结构复杂度说明。仓库同时提供可配置候选截断、warm-up、测量批次、batch size 和设备的 forward-only benchmark；它排除数据读取且不计检索指标。仓库保留这些脚本作为实现参考；本文不声称 timing、显存、吞吐或部署性能结果。

5 实验

5.1 数据集与候选池

我们使用 MassSpecGym 论文发布的划分 [3]，包含 194,119 条训练谱图、19,429 条验证谱图和 17,556 条测试谱图，共计 231,104 条谱图；基准论文报告约 29,000 个唯一分子结构。其相似性感知、结构不重叠构造减少了训练和测试分子之间的近邻结构重叠。

实验评估 MassSpecGym 提供的两种候选设置。质量约束候选池使用前体质量和容差窗口；分子式约束候选池假设已知分子式，因此应解释为 formula-conditioned retrieval，而不是完全开放的未知结构注释。冻结候选池至多包含 256 个候选。reranker 是闭集方法，只能改善所提供候选的顺序，不能恢复候选池之外的分子。

主要评价是 overlap-clean alignment-42 上的 cache-local 矩阵，复用保存的 Base top-40 列表、嵌入和 local exact-target-SMILES 标签。独立身份审计在这些 alignment-42 测试列表上发现二维 InChIKey 标签与本地标签一致。官方候选顺序审计属于另一个 pre-overlap-clean top-256 pilot，两项审计均不是 fresh official-loader 重编码或 alignment 重训。完整范围见 Appendix A。

5.2 实现细节

对齐模型输出 512 维嵌入。谱图 Transformer 为 4 层、16 个 attention heads、宽度 512；分子 GINE 为 4 层、隐藏宽度 128、dropout 0.2。当前实验不加载已发布的 SpecEmbedding checkpoint，因此跳过仅冻结预训练谱图塔的第一训练阶段，并在后续 alignment 阶段使用 MassSpecGym 训练集端到端优化两个编码塔。alignment 使用 AdamW，batch size 128，学习率 10^{-4} ，weight decay 10^{-4} ，cosine schedule，gradient-norm clipping 为 1，最多 100 个 epoch，early stopping patience

为 5。每个 epoch 对每个唯一分子标签采样 10 次，每次随机选择一条关联谱图。谱图和分子图增强分别以 0.5 概率启用：谱图增强删除归一化强度低于 0.3 的碎片峰中 20%（向下取整），并进行 $\pm 15\%$ 强度扰动；图增强执行 10% node dropout 和 10% directed edge-entry dropout。验证关闭增强，但在固定随机流下保留关联谱图的随机采样。当前主 reranker 矩阵使用 seed 42、43、44 产生的 alignment checkpoint。每个 checkpoint 内，reranker seed 42–44 控制初始化、DataLoader 顺序、候选打乱和 dropout；这些 checkpoint 是内部描述性运行，并不等价于来自已知总体的独立抽样。

reranker 隐藏维度为 512，相对分支维度为 32，pair chunk 为 16，dropout 为 0.1。模型先对 $K = 40$ 列表打分，并使用 $K_r = 40$ ； $K = 256$ 是默认完整池配置，不是这些运行的输入规模。优化器为 AdamW，学习率 10^{-4} ，batch size 32，最多训练 30 个 epoch，并根据验证集 MRR 使用 patience 为 5 的 early stopping。pairwise 与谱图依赖损失的权重和 margin 为 $\lambda_{\text{pair}} = 0.2$ 、 $\lambda_{\text{spec}} = 0.1$ 、 $\gamma = 0.1$ 和 $\delta = 0.1$ 。参数近似匹配的 pointwise 对照使用相同绝对分支和优化协议，但不做相对聚合；历史 candidate-set Transformer 仅作为历史参考。

36 个主运行和 30 个消融均从历史 positive-forced top-40 cache 中最多请求 20,000 条训练 query。验证/测试缓存不 forcing，模型按验证 MRR 选择。这不是全量训练或所有 split 都无 forcing 的实验。alignment 与 reranker seed 分别记录，配对组合描述 checkpoint 敏感性，不代表总体层级的不确定性。

5.3 代码、数据与工件可用性

匿名补充包提供源码检查、锁定的环境文件、自动化测试和一个小型 CPU 合成 smoke test。其中不包含真实谱图、候选池、训练 checkpoint 或 cache。仓库的复现索引记录正式结果所用的本地 checkpoint、解析后的配置、日志、哈希和选定的 ranking 输出。真实数据入口及更多复现边界见 Appendix D。仓库源码还包含 query-level case exporter，可为指定 cache query 导出候选身份以及 base/reranker 排名，供后续人工核验；它不执行 fragment attribution，也不生成化学因果解释。

5.4 对比方法与指标

受控比较包括余弦基础检索器、参数近似匹配且无 rank 的 pointwise coarse 打分器和本文提出的相对 reranker；早期 candidate-set Transformer 仅作为历史参考。我们还运行了与 JESTR 类似打分形式的本地保存嵌入 cosine 对照；该对照是 reimplemented control，不是官方 JESTR 编码器或 checkpoint 复现。由于该对照与基础检索器都在相同的保存归一化嵌入上使用 cosine 分数，二者的本地数字一致；因此它是协议匹配的打分控制，而不是独立的 JESTR 比较。GLMR 仍为 reported-only，因为其条件生成流程未在本文中复现。

评价指标为全部 17,556 条测试 query 上的 Recall@1、Recall@5、Recall@10、Recall@20 和 MRR。主要表使用 overlap-clean alignment seed 42 的 cache-local top-40 顺序和 exact-target-SMILES 标签，测试不 forcing；使用三个 reranker training seeds (42–44) 以及最多 20,000 条训练 query；另一个表报告 alignment seeds 42–44 的相同 pointwise/relative 对照。均值和样本标准

表 2: overlap-clean alignment-42 上的 cache-local top-40 评价。数值为百分比；学习式结果为 reranker seeds 42–44 的均值 $\pm$ 样本标准差。测试使用同一保存候选池与 exact-target-SMILES 标签且不 forcing；训练缓存插入正例并限制为最多 20,000 query。扩展的 alignment 敏感性见表 3。

候选池	方法	R@1	R@5	R@10	R@20	MRR
质量	SpecMolAlign (top-40 缓存池)	47.46	63.51	71.02	77.76	55.03
	Pointwise 对照	58.12 $\pm$ 0.54	73.61 $\pm$ 0.54	78.63 $\pm$ 0.48	82.24 $\pm$ 0.10	64.91 $\pm$ 0.47
	相对候选模型	57.88 $\pm$ 0.59	73.55 $\pm$ 0.58	78.72 $\pm$ 0.29	82.15 $\pm$ 0.13	64.78 $\pm$ 0.52
分子式	SpecMolAlign (top-40 缓存池)	63.10	75.79	80.87	84.93	68.86
	Pointwise 对照	70.76 $\pm$ 0.59	80.07 $\pm$ 0.35	84.33 $\pm$ 0.08	86.86 $\pm$ 0.08	75.17 $\pm$ 0.41
	相对候选模型	70.88 $\pm$ 0.38	80.60 $\pm$ 0.37	84.68 $\pm$ 0.26	86.85 $\pm$ 0.09	75.38 $\pm$ 0.27

表 3: top-40 协议下的 alignment checkpoint 描述性敏感性：训练 forcing，验证/测试不 forcing。学习式结果为 reranker seeds 42–44 的均值；该矩阵未重新通过 official loader 编码。

alignment	候选池	Base R@1/MRR	Pointwise R@1/MRR	Relative R@1/MRR
42	质量	47.46/.5503	58.12/.6491	57.88/.6478
43	质量	35.92/.4433	58.32/.6398	57.61/.6350
44	质量	23.91/.3226	46.42/.5238	47.05/.5284
42	分子式	63.10/.6886	70.76/.7517	70.88/.7538
43	分子式	45.08/.5185	64.72/.6836	64.10/.6795
44	分子式	28.73/.3687	54.26/.5877	54.35/.5911

差在单个 alignment 内描述 reranker 离散度，跨 alignment 行是 checkpoint 敏感性描述，不是总体重复。本文不声称官方 JESTR 复现、统计显著性或端到端部署性能。

5.5 主要结果

两种学习式模型在两个候选池都超过 alignment-42 的 Base。Pointwise 在质量场景的 R@1 和 MRR 略高于 relative (58.12 对 57.88、0.6491 对 0.6478)，而 relative 在分子式场景略高 (70.88 对 70.76、0.7538 对 0.7517)。这些描述性差异不能建立相对模块的独立收益。仓库保留了评价时候选 cutoff 文件，但它们不是按候选规模重新训练的模型，也不构成额外的主要结果。

这一受控比较形成本文的两部分发现：在所提供候选池内，监督式第二阶段打分确实有用；但当前观测到的改善并不要求相对交互，而且 relative 并未在匹配的 pointwise 对照上普遍占优。后一个结果是所提机制的适用边界，而不是需要隐藏的比较失败。

在每个候选协议的九组 alignment-reranker-seed 配对中，relative 减 pointwise 的 R@1 平均差在质量和分子式场景分别为 -0.11 和 -0.14 个百分点，MRR 平均差分别为 -0.0005 和 $+0.0005$ ；两种候选协议中 relative 均在 9 组配对中的 5 组取得较高 R@1。这些是描述性配对估计，不是显著性检验，支持的结论是监督重排序框架比任何独立的 relative 模块优势更稳妥。

机制分析。 表 4 报告完整的 30 次 relative 模块消融矩阵：5 种 relative 配置、两种候选协议以及三个 reranker seed，均在 alignment-42 checkpoint 上运行。完整配置为带谱图条件的反对称模型。

表 4: cache-local top-40 协议下的 relative 消融：训练 forcing，验证/测试不 forcing。R@1 使用百分比，MRR 使用小数；每项为 reranker seeds 42–44 的均值 $\pm$ 样本标准差。

变体	质量 R@1/MRR		分子式 R@1/MRR	
完整反对称	57.88 $\pm$ 0.59	/ .6478 $\pm$.0052	70.88 $\pm$ 0.38	/ .7538 $\pm$.0027
Directed pair	57.97 $\pm$ 0.49	/ .6471 $\pm$.0047	70.06 $\pm$ 1.29	/ .7471 $\pm$.0106
移除谱图条件	58.42 $\pm$ 0.81	/ .6522 $\pm$.0069	71.01 $\pm$ 0.40	/ .7546 $\pm$.0033
移除 $\mathcal{L}_{\text{pair}}$	58.01 $\pm$ 0.38	/ .6488 $\pm$.0037	70.91 $\pm$ 0.36	/ .7541 $\pm$.0027
移除 $\mathcal{L}_{\text{spec}}$	58.44 $\pm$ 0.54	/ .6516 $\pm$.0064	70.59 $\pm$ 0.79	/ .7515 $\pm$.0056

移除谱图条件后，两个候选池的平均 R@1 和 MRR 均提高；其它改动的方向随指标和候选协议改变。这些聚合结果未建立谱图条件的独立收益，也不构成组件因果排序。

JESTR 和 GLMR 保留为 reported-only 的相关工作背景；本文不据此推断相对排名。

困难候选分层。 在 seed-42 本地 query 分析中，选定的有标签子集包含质量 14,726 条和分子式 15,670 条 query。relative 模型在基础排名为 2–5/6–20/21–40 时相对 Base 的 R@1 增益，质量场景分别为 +54.05/+38.13/+29.98 个百分点，分子式场景分别为 +55.41/+34.18/+19.10 个百分点。基础排名为 1 的 query 则下降到质量 87.41%、分子式 95.12%，而 Base 分层为 100%。Pointwise 对照也呈现相同的未解决 query 模式；这些分层是描述性分析，不建立相对模块的因果效应。

早期含 rank 的 Transformer 结果和协议说明移至 Appendix B，不作为当前相对方法的性能证据。

6 讨论

扩展 cache-local 矩阵将候选覆盖与列表内排序分开。alignment-42 的 top-40 测试列表中，质量/分子式 coverage 上界分别为 83.88%/89.26%。三个 alignment checkpoint 内，两种模型都超过对应 Base；relative 与 pointwise 的排序随候选池、指标和 checkpoint 改变。该结果支持监督第二阶段重排序作为框架组件，但不能隔离相对模块的独立收益。

30 次消融显示，directed 与 antisymmetric pair、谱图条件以及两项辅助损失对两个候选池的影响方向不同。这些结果是描述性分析，用于说明方法行为，不构成组件因果收益。

relative 分支的结构计算成本也高于 pointwise：完整候选池的绝对分支为 $O(Kd)$ ，coarse 子集上的 pair 计算为 $O(K_r^2 d)$ 。仓库保留固定硬件的 forward-only 测量作为实现参考；本文不将其解释为端到端 latency、吞吐或部署性能结论。

主要矩阵复用 cache-local 候选顺序和保存的 alignment 嵌入；另有独立的 official-compatible 审计使用发布的候选 JSON 和 pilot 的保存嵌入，但没有通过新建的 official loader 重新编码谱图/分子，也没有重训第一阶段。因此它不能证明另行重建的 loader、不同候选来源或外部方法的端到端等价性。

7 局限性与负责任评估

扩展 reranker 矩阵最多请求 20,000 条训练 query，评价三个 alignment checkpoint，并在每个主要配置上使用三个 reranker seed。训练使用插入正例的 top-40 cache，验证/测试不 forcing，因此不能验证全量训练、top-256、全 split no-forcing 的效果。这提供描述性 checkpoint 敏感性，而不是置信区间、显著性检验或完整端到端 seed 分析。评价复用保存嵌入和所提供候选池，不声称重新通过官方 loader 编码、外部 baseline 复现或候选感知 alignment 重训。这些限制也界定了本文的两部分发现：框架级重排序观察在所评价 checkpoint 内得到支持，而 relative 模块的普适性仍未确定。

本文方法是闭集方法，在分子式协议下还假设分子式已知。它不能恢复候选池之外的目标，也不能自动迁移到其它候选构造和采集条件。谱图塔使用选定峰和前体 m/z ，但不显式接收加合物、仪器或碰撞能量元数据。其 pairwise 结构约束也不提供概率校准或全局一致排序保证。更多协议和复现边界见 Appendix A 和 Appendix D。

8 结论

本文提出 SpecEmbedding-Rerank：一种无 rank 的第二阶段排序器，将完整候选池 coarse 分与谱图条件的相对候选偏好结合。在扩展的 cache-local 矩阵中，三个 alignment checkpoint 内的 relative 和参数近似匹配的 pointwise 都改善质量和分子式场景的对应 Base；主要表使用 overlap-clean alignment-42 的 top-40 缓存，训练最多使用 20,000 query 并仅在训练时插入正例。独立审计在各自保存缓存范围内核对候选顺序与二维身份。relative 与 pointwise 的排序依赖候选池和指标，30 次消融也未建立 relative 组件的统一独立优势。因此，当前证据支持一个边界明确的监督式重排序框架，并明确了 relative 交互的边界：它是具有结构依据的候选关系机制，但当前证据尚未建立其相对 pointwise 打分的独立且普遍稳健收益。本文方法仍限于固定的保存嵌入候选协议。

A 评价协议与候选身份

主要矩阵使用 local exact-target-SMILES 标签和保存的 Base top-40 列表。对 overlap-clean alignment-42 测试缓存的独立二维 InChIKey 审计没有发现额外正例或候选身份碰撞：每池 17,556 query 中，质量 14,726 条、分子式 15,670 条有正例。两种身份规则在这些列表上一致，无正例仍计 coverage miss；不能将该审计直接继承给其它 checkpoint 或候选截断。

官方顺序审计使用另一 pre-overlap-clean alignment 的 top-256 no-forcing pilot（5,000 条训练 query、3 epochs、reranker seeds 42–44）。其候选集合与 MassSpecGym 1.3.1 retrieval JSON 一致，完整池身份审计在每个 test query 上发现一个等价正例。重排该列表并用保存嵌入重新打分不等于重跑官方 loader 或 alignment，也不能使主要 top-40 矩阵成为官方评价。

谱图记录审计发现 6 条 validation 和 3 条 test 记录与训练输入相同，但分子标签不同。overlap-clean alignment validation 排除了受影响记录；这不代表所有后续 reranker 都使用相同排除项。候

选 cutoff 均为评价时截断: pilot 使用 top-256 缓存, 扩展矩阵使用自身的 top-40 缓存, 二者都不是按 cutoff 分别重训。

B 实现细节与历史对照

当前训练入口在新 reranker checkpoint 中写入 `data_summary`: 实际有标签训练 query 数、请求上限、`train_k`、model type、pair mode、seed 与可用的 cache 元数据。这些字段用于区分训练范围与 forcing 语义, 不改变 forward, 也不替代实验。

历史 Candidate-Set Transformer 使用 rank embedding 和通用 candidate self-attention。它与已报告 top-40 矩阵共享历史训练 forcing 约定, 但架构和容量不同, 不能作为参数近似匹配的 pointwise 对照。默认 top-256 no-forcing 配置与这些历史测量保持区分。

C 补充机制分析

表 4 的 30 次运行包含 5 种配置、两种候选协议和三个 reranker seed。正文的困难分层描述保存候选池中的重排空间, 不识别相对模块的因果效应。评价 cutoff 与固定硬件前向测量只作为实现参考, 不是重训或端到端部署基准。

D 复现与负责任评价说明

复现索引记录已报告矩阵的 source commit、解析配置、cache 元数据、checkpoint/日志哈希和选定的 ranking 输出。匿名补充包提供源码检查、锁定环境、测试和 synthetic CPU smoke, 排除真实谱图、候选池、cache、checkpoint 与内部工件索引; smoke 验证执行, 不复现科学指标。

参考文献

- [1] Eric Bach, Emma L. Schymanski, and Juho Rousu. Joint structural annotation of small molecules using liquid chromatography retention order and tandem mass spectrometry data. *Nature Machine Intelligence*, 4(12):1224–1237, 2022.
- [2] Chris Burges, Tal Shaked, Erin Renshaw, Ari Lazier, Matt Deeds, Nicole Hamilton, and Greg Hullender. Learning to rank using gradient descent. In *Proceedings of the 22nd International Conference on Machine Learning*, pages 89–96, 2005.
- [3] Roman Bushuiev, Anton Bushuiev, Niek F. de Jonge, Adamo Young, Fleming Kretschmer, Raman Samusevich, Janne Heirman, Fei Wang, Luke Zhang, Kai Dührkop, Marcus Ludwig, Nils A. Haupt, Apurva Kalia, Corinna Brungs, Robin Schmid, Russell Greiner, Bo Wang, David S. Wishart, Li-Ping Liu, Juho Rousu, Wout Bittremieux, Hannes Röst, Tytus D. Mak,

- Soha Hassoun, Florian Huber, Justin J. J. van der Hooft, Michael A. Stravs, Sebastian Böcker, Josef Sivic, and Tomáš Pluskal. MassSpecGym: A benchmark for the discovery and identification of molecules. In *Advances in Neural Information Processing Systems*, volume 37, pages 110010–110027, 2024.
- [4] Zhe Cao, Tao Qin, Tie-Yan Liu, Ming-Feng Tsai, and Hang Li. Learning to rank: From pairwise approach to listwise approach. In *Proceedings of the 24th International Conference on Machine Learning*, pages 129–136, 2007.
- [5] Lu Chen, Bing Xia, Yu Wang, Xia Huang, Yucheng Gu, Wenlin Wu, and Yan Zhou. CMSSP: A contrastive mass spectra-structure pretraining model for metabolite identification. *Analytical Chemistry*, 96(42):16871–16881, 2024.
- [6] Yan Zhou Chen and Soha Hassoun. Learning from all views: A multiview contrastive framework for metabolite annotation. *Analytical Chemistry*, 98(9):6598–6606, 2026.
- [7] Niek F. de Jonge, Joris J. R. Louwen, Elena Chekmeneva, Stephane Camuzeaux, Femke J. Vermeir, Robert S. Jansen, Florian Huber, and Justin J. J. van der Hooft. MS2Query: Reliable and scalable MS2 mass spectra-based analogue search. *Nature Communications*, 14(1):1752, 2023.
- [8] Kai Dührkop, Huibin Shen, Marvin Meusel, Juho Rousu, and Sebastian Böcker. Searching molecular structure databases with tandem mass spectra using CSI:FingerID. *Proceedings of the National Academy of Sciences*, 112(41):12580–12585, 2015.
- [9] Michael Gerlich and Steffen Neumann. MetFusion: Integration of compound identification strategies. *Journal of Mass Spectrometry*, 48(3):291–298, 2013.
- [10] Samuel Goldman, Jeremy Wohlwend, Martin Stražar, Guy Haroush, Ramnik J. Xavier, and Connor W. Coley. Annotating metabolite mass spectra with domain-inspired chemical formula transformers. *Nature Machine Intelligence*, 5(9):965–979, 2023.
- [11] Weihua Hu, Bowen Liu, Joseph Gomes, Marinka Zitnik, Percy Liang, Vijay Pande, and Jure Leskovec. Strategies for pre-training graph neural networks. In *International Conference on Learning Representations*, 2020.
- [12] Apurva Kalia, Yan Zhou Chen, Dilip Krishnan, and Soha Hassoun. JESTR: Joint embedding space technique for ranking candidate molecules for the annotation of untargeted metabolomics data. *Bioinformatics*, 41(7):btaf354, 2025.
- [13] Juho Lee, Yoonho Lee, Jungtaek Kim, Adam Kosiorek, Seungjin Choi, and Yee Whye Teh. Set transformer: A framework for attention-based permutation-invariant neural networks. In *Pro-*

- ceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3744–3753. PMLR, 2019.
- [14] Liang Pang, Jun Xu, Qingyao Ai, Yanyan Lan, Xueqi Cheng, and Jirong Wen. SetRank: Learning a permutation-invariant ranking model for information retrieval. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 499–508, 2020.
- [15] Michael A. Stravs, Kai Dührkop, Sebastian Böcker, and Nicola Zamboni. MSNovelist: De novo structure generation from mass spectra. *Nature Methods*, 19(7):865–870, 2022.
- [16] Yonglong Tian, Dilip Krishnan, and Phillip Isola. Contrastive multiview coding. In *Computer Vision – ECCV 2020*, volume 12356 of *Lecture Notes in Computer Science*, pages 776–794, Cham, 2020. Springer.
- [17] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008, 2017.
- [18] Peng Xiong, Hongtao Xu, and Haoran Zheng. Supervised contrastive learning leads to more reasonable spectral embeddings. *Analytical Chemistry*, 97(37):20137–20146, 2025.
- [19] Adamo Young, Hannes Röst, and Bo Wang. Tandem mass spectrum prediction for small molecules using graph transformers. *Nature Machine Intelligence*, 6(4):404–416, 2024.
- [20] Yiwen Zhang, Keyan Ding, Yihang Wu, Xiang Zhuang, Yi Yang, Qiang Zhang, and Huajun Chen. Breaking the modality barrier: Generative modeling for accurate molecule retrieval from mass spectra. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(2):1561–1569, 2026.